

LAPORAN AKHIR MAGANG

**“Pengembangan Sistem Klasifikasi Otomatis pada Web Radar K3
Menggunakan Model Deep Learning Berbasis IndoBERT untuk Mendukung
Penentuan Skor Risiko”**

PT. PLN NUSANTARA POWER UP PAITON UNIT 1-2



Penyusun:

Shazrin Fhariza Amerta

(23031554150)

**UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA & ILMU PENGETAHUAN ALAM PROGRAM
STUDI SAINS DATA
TAHUN 2026**

Lembar Pengesahan

Judul Kegiatan	Magang MBKM
Nama Instansi	PT. PLN Nusantara Power UP Paiton
Alamat Instansi	Jl. Raya Surabaya-Situbondo No.Km.142, Area Sawah, Bhinor, Kec. Paiton, Kabupaten Probolinggo, Jawa Timur 67291
Identitas mahasiswa	
Nama	Shazrin Fhariza Amerta
NIM	23031554150
Prodi/Jurusan Fakultas	S1 Sains Data
Alamat Email	Matematika dan Ilmu Pengetahuan Alam shazrin.23150@mhs.unesa.ac.id
Periode Magang	01 April 2026 s.d. 30 Juni 2026

Probolinggo, 30 Juni 2026

Mengetahui,

Dosen Pembimbing Lapangan



Ibnu Febry Kurniawan, S.Kom., M.Sc., Ph.D.
NIP. 198802182015041001

Mahasiswa



Shazrin Fhariza Amerta
NIM. 23031554150

Menyetujui,

Pembimbing Mitra



Heri Purnomo
NID. 8312771PT

Koordinator Program Studi



Yuliani Puji Astuti, S.Si., M.Si.
NIP. 197807312006042001

DAFTAR ISI

DAFTAR ISI	III
DAFTAR TABEL	V
DAFTAR GAMBAR	VI
BAB I	1
PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Manfaat	2
1.5 Ruang Lingkup Pembahasan	3
BAB II	4
GAMBARAN UMUM PERUSAHAAN	4
2.1 Sejarah Singkat Perusahaan	4
2.2 Struktur Organisasi Perusahaan	5
2.3 Lokasi Perusahaan	6
2.4 Kesehatan dan Keselamatan Kerja	6
2.5 Etika Profesi	7
BAB III	9
HASIL KEGIATAN KERJA	9
3.1 Alur Pembangkit Listrik Tenaga Uap (PLTU)	9
3.2 Sistem Keselamatan dan Kesehatan Kerja (K3)	9
3.2.1 Penerapan K3	10
3.2.2 Sistem Pelaporan K3	10
3.2.3 Kategori Temuan K3	11
3.3 Pengembangan Sistem Klasifikasi Otomatis Laporan K3	11
3.3.1 Identifikasi Masalah	11
3.3.2 Sistem Sebelum Pengembangan	12
3.3.3 Pengumpulan Data	13
3.3.4 Penyusunan Dataset	13
3.3.5 penyusunan Dataset Awal	13
3.3.6 Pemuatan Panduan Kategori Perusahaan	15
3.3.7 Text Preprocessing	15
3.4 Pembangunan Dataset	17
3.4.1 Penyusunan Aturan Keyword	17
3.4.2 Semi-supervised Labeling	18
3.4.3 Audit Hasil Semi-supervised Labeling	21
3.4.4 Crosscheck Berdasarkan Pola Kesalahan Audit	23
3.5 Penyusunan Dataset Final	25
3.5.1 Penggabungan Dataset Hasil Pelabelan	25
3.5.2 Finalisasi Dataset untuk Pelatihan IndoBERT	26

3.6 Implementasi Model IndoBERT.....	29
3.6.1 Persiapan Model IndoBERT.....	29
3.6.2 Tokenisasi Data Menggunakan IndoBERT	32
3.6.3 Pembentukan Dataset PyTorch.....	33
3.6.4 Penanganan Ketidakseimbangan Data Menggunakan Class Weight.....	35
3.6.5 Pembangunan Model IndoBERT.....	36
3.6.6 Proses Fine-Tuning Model IndoBERT	37
3.6.7 Evaluasi Model IndoBERT.....	40
3.6.8 Analisis Confusion Matrix.....	41
3.6.9 Penyimpanan Model IndoBERT.....	43
3.7 Implementasi Model pada Web K3	44
3.7.1 Persiapan Deployment Model.....	44
3.7.2 Deployment API Menggunakan FastAPI	45
3.7.3 Pengujian API Menggunakan Swagger	47
3.7.4 Integrasi API ke Souece Code Web &K3.....	48
3.7.5 Implementasi Fitur Prediksi pada Web K3.....	49
BAB IV.....	51
KESIMPULAN DAN SARAN	51
4.1 Kesimpulan.....	51
4.2 Saran	51
DAFTAR PUSTAKA	52
LAMPIRAN	53

DAFTAR TABEL

Tabel 3.2.1 Kategori Temuan K3	11
Tabel 3.3.1 Pembentukan Dataset Awal	14
Tabel 3.4.1 Hasil Semi-supervised Labeling	20
Tabel 3.4.2 Hasil Audit Semi-supervised Labeling	22
Tabel 3.4.3 Hasil Crosscheck Dataset	23
Tabel 3.5.1 Komposisi Dataset Final	25
Tabel 3.5.2 Hasil Finalisasi Dataset	27
Tabel 3.6.1 Implementasi Proses Label Encoding	30
Tabel 3.6.2 Nilai Class Weight	35
Tabel 3.6.3 Parameter Fine-Tuning IndoBERT	38
Tabel 3.6.4 Hasil Penyimpanan Model IndoBERT	44

DAFTAR GAMBAR

Gambar 2.1.1 PLTU Paiton	4
Gambar 2.2.1 Struktur Organisasi PLN Nusantara Power UP Paiton	5
Gambar 2.3.1 Lokasi PLN Nusantara Power UP Paiton	6
Gambar 2.5.1 Etika Profesi PLN Nusantara Power	7
Gambar 3.3.1 Alur Sistem Sebelum Pengembangan	12
Gambar 3.3.2 Penyusunan Dataset	14
Gambar 3.3.3 Hasil Pembacaan Panduan Kategori dan Bobot Perusahaan.....	15
Gambar 3.3.4 Implementasi Fungsi Text Preprocessing	16
Gambar 3.3.5 Tahapan Text Preprocessing	17
Gambar 3.3.6 Hasil Text Preprocessing	17
Gambar 3.4.1 Implementasi Aturan Keyword pada Proses Semi-supervised Labeling	18
Gambar 3.4.2 Implementasi Aturan Penentuan Kategori Awal Menggunakan Keyword Matching.....	19
Gambar 3.4.3 Implementasi Koreksi Kategori Menggunakan Aturan Tambahan (Fix Ambiguous)	19
Gambar 3.4.4 Implementasi Koreksi Berdasarkan Pola Khusus Laporan K3	19
Gambar 3.4.5 Hasil Penerapan Semi-supervised Labeling pada Dataset K3	20
Gambar 3.4.6 Proses Penyimpanan Dataset Hasil Auto Labeling.....	20
Gambar 3.4.7 Proses Penyimpanan Dataset yang Memerlukan Pelabelan Manual.....	21
Gambar 3.4.8 Dataset Sebelum Pelabelan Manual.....	21
Gambar 3.4.9 Dataset Setelah Pelabelan Manual	21
Gambar 3.4.10 Proses Pengambilan Sampel Audit Sebanyak 300 Data	22
Gambar 3.4.11 Dataset Hasil Audit Manual.....	22
Gambar 3.4.12 Proses Integrasi Hasil Audit ke Dataset Utama	23
Gambar 3.4.13 Proses Pencarian Kandidat Crosscheck Berdasarkan Pola Kesalahan.....	24
Gambar 3.4.14 Dataset Hasil Crosscheck.....	24
Gambar 3.4.15 Integrasi Hasil Crosscheck ke Dataset Utama	24
Gambar 3.5.1 Dataset Hasil Semi-supervised Labeling Setelah Validasi	25
Gambar 3.5.2 Dataset Hasil Pelabelan Manual	26
Gambar 3.5.3 Proses Penggabungan Kedua Dataset Menggunakan Pandas	26
Gambar 3.5.4 Dataset Final Hasil Penggabungan Sebanyak 4.108 Data	26
Gambar 3.5.5 Distribusi Dataset Berdasarkan Kategori.....	27
Gambar 3.5.6 Proses Finalisasi Dataset Sebelum Pelatihan Model IndoBERT	28
Gambar 3.5.7 Hasil Proses Finalisasi	29
Gambar 3.6.1 Implementasi Pembacaan Dataset Hasil Finalisasi Menggunakan Pandas	30
Gambar 3.6.2 Pembacaan Dataset dataset_indobert_ready.xlsx.....	31
Gambar 3.6.3 Implementasi Proses Label Encoding	31
Gambar 3.6.4 Hasil Label Encoding.....	31
Gambar 3.6.5 Distribusi Pembagian Dataset Training, Validation, dan Testing.....	32
Gambar 3.6.6 Implementasi Pemanggilan Token IndoBERT	32
Gambar 3.6.7 Implementasi Proses Tokenisasi Dataset	33
Gambar 3.6.8 Implementasi Pembentukan Kelas K3 Dataset	34
Gambar 3.6.9 Implementasi Pembentukan Dataset Training, Validation, dan Testing.....	34
Gambar 3.6.10 Implementasi Perhitungan Class Weight	35
Gambar 3.6.11 Hasil Perhitungan Class Weight	36
Gambar 3.6.12 Implementasi Pemanggilan Model IndoBERT	36

Gambar 3.6.13 Informasi Inisialisasi Lapisan Klasifikasi IndoBERT	37
Gambar 3.6.14 Implementasi Fungsi compute_metrics	37
Gambar 3.6.15 Implementasi TrainingArguments	38
Gambar 3.6.16 Implementasi Pembentukan Objek Trainer.....	39
Gambar 3.6.17 Implementasi Proses fine-tuning IndoBERT	39
Gambar 3.6.18 Hasil fine-tuning Model IndoBERT	39
Gambar 3.6.19 Implementasi Proses Evaluasi Model Menggunakan Data Testing	40
Gambar 3.6.20 Hasil Classification Report Model IndoBERT	41
Gambar 3.6.21 Implementasi Pembuatan Confusion Matrix Menggunakan Scikit-learn	42
Gambar 3.6.22 Hasil Confusion Matrix Model IndoBERT.....	42
Gambar 3.6.23 Implementasi Penyimpanan Model IndoBERT, Tokenizer, dan Label Encoder	44
Gambar 3.7.1 Struktur Folder Deployment Model IndoBERT K3.....	45
Gambar 3.7.2 Implementasi Layanan Prediksi Menggunakan FastAPI.	46
Gambar 3.7.3 Deployment API Menggunakan Uvicorn pada Server Perusahaan.	47
Gambar 3.7.4 Halaman Pengujian Endpoint Prediksi Menggunakan Swagger UI.....	48
Gambar 3.7.5 Implementasi Integrasi Layanan Prediksi IndoBERT pada Backend Web K3.....	49
Gambar 3.7.6 Implementasi Fitur Predict AI pada Aplikasi Web K3	50

BAB I

PENDAHULUAN

1.1 Latar Belakang

PT PLN Nusantara Power UP Paiton Unit 1-2 merupakan salah satu unit pembangkit listrik tenaga uap (PLTU) dengan kapasitas total 800 MW yang memiliki peran penting dalam menjaga keandalan pasokan listrik pada sistem kelistrikan Jawa-Bali. Dalam operasional pembangkit listrik, aspek Keselamatan dan Kesehatan Kerja (K3) menjadi prioritas utama karena aktivitas kerja melibatkan berbagai peralatan bertegangan tinggi, mesin berkapasitas besar, material berbahaya, serta lingkungan kerja yang memiliki tingkat risiko tinggi. Oleh karena itu, penerapan budaya K3 secara konsisten diperlukan untuk mencegah terjadinya kecelakaan kerja, kerusakan peralatan, maupun gangguan operasional pembangkit.

Sebagai upaya peningkatan budaya keselamatan kerja, PLN telah menerapkan digitalisasi dalam pengelolaan dan pelaporan aspek K3. Salah satu implementasinya adalah penggunaan sistem pelaporan yang memungkinkan seluruh pekerja untuk melaporkan temuan kondisi tidak aman (*unsafe condition*) maupun tindakan tidak aman (*unsafe action*) yang ditemukan di lingkungan kerja. Setiap laporan yang masuk harus diklasifikasikan ke dalam kategori tertentu, seperti *Housekeeping & 5S*, *Fire & Emergency System*, Peralatan & Mesin, APD (Alat Pelindung Diri), dan Perilaku Kerja (*Behavior*). Klasifikasi ini bertujuan untuk memudahkan proses monitoring, evaluasi, dan tindak lanjut oleh tim K3.

Namun, proses pengelompokan laporan pada sistem yang digunakan saat ini masih dilakukan secara manual oleh petugas K3. Seiring meningkatnya jumlah laporan yang masuk setiap hari, proses klasifikasi menjadi semakin kompleks dan membutuhkan waktu yang cukup lama. Selain itu, perbedaan pemahaman antar petugas terhadap isi laporan dapat menyebabkan terjadinya kesalahan dalam penentuan kategori. Kondisi tersebut berpotensi mengurangi efisiensi pengelolaan data K3 serta memengaruhi keakuratan informasi yang digunakan dalam pengambilan keputusan terkait keselamatan kerja.

Perkembangan teknologi *Artificial Intelligence* (AI), khususnya *Machine Learning* (ML) dan *Natural Language Processing* (NLP), memungkinkan proses klasifikasi teks dilakukan secara otomatis berdasarkan pola yang dipelajari dari data historis. Teknologi ini telah banyak diterapkan untuk mengelompokkan dokumen, menganalisis laporan keselamatan, serta mengidentifikasi kategori kejadian berdasarkan deskripsi teks yang diberikan. Dengan memanfaatkan data laporan K3 yang telah tersedia, model *Machine Learning* dapat dilatih untuk mengenali karakteristik setiap kategori dan memberikan prediksi secara otomatisasi terhadap laporan baru.

Berdasarkan permasalahan tersebut, pada proyek ini dilakukan pengembangan model klasifikasi teks berbasis *Machine Learning* untuk mengotomatisasi proses kategorisasi laporan K3 pada sistem pelaporan di PT PLN Nusantara Power UP Paiton Unit 1-2. Diharapkan solusi yang dihasilkan dapat membantu meningkatkan efisiensi kerja tim K3, mengurangi potensi kesalahan klasifikasi, serta mendukung proses pengelolaan data keselamatan kerja yang lebih cepat dan akurat.

1.2 Rumusan Masalah

Berdasarkan uraian latar belakang yang telah dijelaskan, maka rumusan masalah dalam proyek ini adalah sebagai berikut:

1. Bagaimana proses pengembangan model *Machine Learning* yang dapat mengklasifikasikan laporan K3 secara otomatis berdasarkan deskripsi temuan yang dilaporkan oleh pekerja?
2. Bagaimana tingkat performa model *Machine Learning* dalam mengelompokkan laporan K3 ke dalam kategori *Housekeeping & 5S*, *Fire & Emergency System*, Peralatan & Mesin, APD (Alat Pelindung Diri), dan Perilaku Kerja (*Behavior*)?
3. Bagaimana penerapan model klasifikasi otomatis dapat membantu meningkatkan efisiensi proses pengelolaan laporan K3 dibandingkan dengan proses klasifikasi yang dilakukan secara manual?

1.3 Tujuan

Berdasarkan rumusan masalah yang telah ditetapkan, tujuan dari pelaksanaan proyek ini adalah sebagai berikut:

1. Mengembangkan model *Machine Learning* yang mampu mengklasifikasikan laporan K3 secara otomatis berdasarkan deskripsi temuan yang dilaporkan oleh pekerja.
2. Mengukur dan mengevaluasi performa model *Machine Learning* dalam mengelompokkan laporan K3 ke dalam kategori *Housekeeping & 5S*, *Fire & Emergency System*, Peralatan & Mesin, APD (Alat Pelindung Diri), dan Perilaku Kerja (*Behavior*).
3. Membantu meningkatkan efisiensi proses pengelolaan laporan K3 dengan mengurangi ketergantungan pada proses klasifikasi manual yang dilakukan oleh tim K3.
4. Mengurangi potensi kesalahan klasifikasi laporan serta mendukung penyediaan data K3 yang lebih cepat, akurat, dan konsisten untuk kebutuhan monitoring dan evaluasi keselamatan kerja di PT PLN Nusantara Power UP Paiton Unit 1-2.

1.4 Manfaat

Adapun manfaat yang diperoleh dalam pelaksanaan Program Magang yaitu:

1. Bagi Mahasiswa

- Memberikan pengalaman kerja nyata yang relevan dengan bidang keilmuan Sains Data, khususnya dalam penerapan *Machine Learning* dan Natural Language Processing (NLP) pada permasalahan industri.
- Menjadi sarana penerapan ilmu yang diperoleh selama perkuliahan, seperti pengolahan data, data preprocessing, klasifikasi teks, evaluasi model *Machine Learning*, dan analisis data
- Meningkatkan kompetensi teknis dalam pengembangan model klasifikasi data berbasis *Machine Learning* serta kompetensi non-teknis seperti komunikasi, kerja sama tim, pemecahan masalah, dan manajemen waktu.
- Menambah pemahaman mengenai penerapan Keselamatan dan Kesehatan Kerja (K3) di lingkungan industri pembangkit tenaga listrik.
- Menumbuhkan sikap profesional dan kesiapan dalam menghadapi tantangan dunia kerja melalui keterlibatan langsung pada proyek yang mendukung kebutuhan operasional perusahaan.

2. Bagi Mitra (PT. PLN Nusantara Power UP Paiton)

- Membantu meningkatkan efisiensi proses pengelolaan laporan K3 melalui penerapan sistem klasifikasi otomatis berbasis *Machine Learning*.

- Mengurangi potensi kesalahan klasifikasi yang dapat terjadi pada proses pengelompokan laporan secara manual.
- Mempercepat proses identifikasi dan pengelompokan laporan K3 sehingga memudahkan tim K3 dalam melakukan monitoring dan tindak lanjut terhadap temuan yang dilaporkan.
- Mendukung upaya transformasi digital perusahaan melalui pemanfaatan teknologi *Artificial Intelligence* dan *data analytics* dalam proses bisnis K3.
- Menyediakan model klasifikasi yang dapat dikembangkan lebih lanjut untuk mendukung pengambilan keputusan berbasis data di lingkungan perusahaan.

3. Bagi Universitas Negeri Surabaya (UNESA)

- Meningkatkan kualitas lulusan yang memiliki pengalaman praktis dalam penerapan ilmu Sains Data pada permasalahan nyata di dunia industri.
- Menjadi bahan evaluasi dan pengembangan kurikulum agar tetap selaras dengan kebutuhan kompetensi yang dibutuhkan oleh dunia kerja, khususnya pada bidang *data science*, *machine learning*, dan transformasi digital.
- Menambah referensi penerapan keilmuan Sains Data dalam lingkungan industri yang dapat dimanfaatkan sebagai bahan pembelajaran maupun penelitian selanjutnya.
- Meningkatkan reputasi insitusi melalui keterlibatan aktif mahasiswa dalam menyelesaikan permasalahan nyata serta menghasilkan solusi berbasis teknologi yang memberikan manfaat bagi perusahaan.

1.5 Ruang Lingkup Pembahasan

Adapun ruang lingkup pembahasan dalam menyusun laporan magang ini adalah sebagai berikut:

1. Tinjauan umum mengenai PT PLN Nusantara Power UP Paiton Unit 1-2 yang mencakup profil perusahaan, sejarah singkat perusahaan, struktur organisasi, serta penerapan Keselamatan dan Kesehatan Kerja (K3) di lingkungan kerja perusahaan.
2. Pembahasan difokuskan pada pengembangan model Machine Learning untuk melakukan klasifikasi otomatis terhadap laporan K3 berdasarkan deskripsi temuan yang dilaporkan oleh pekerja.
3. Data yang digunakan merupakan data historis laporan K3 PT PLN Nusantara Power UP Paiton Unit 1-2 selama periode Januari 2025 hingga Desember 2025
4. Kategori klasifikasi yang digunakan dalam penelitian ini meliputi *Housekeeping & 5S*, *Fire & Emergency System*, Peralatan & Mesin, APD (Alat Pelindung Diri), dan Perilaku Kerja (*Behavior*).
5. Proses pengolahan data meliputi tahapan pembersihan data (*data cleaning*), *preprocessing* teks, transformasi fitur, pelatihan model *Machine Learning*, serta evaluasi performa model klasifikasi.
6. Evaluasi performa model dilakukan menggunakan metrik klasifikasi seperti *accuracy*, *precision*, *recall*, dan *F1-score*.

BAB II

GAMBARAN UMUM PERUSAHAAN

2.1 Sejarah Singkat Perusahaan

PT PLN Nusantara Power merupakan subholding pembangkitan di bawah PT PLN (Persero) yang sebelumnya dikenal sebagai PT Pembangkitan Jawa-Bali (PJB). Perubahan nama menjadi PT PLN Nusantara Power dilakukan sebagai bagian dari transformasi organisasi PLN untuk memperkuat pengelolaan sektor pembangkitan tenaga listrik di Indonesia.

Salah satu unit pembangkit yang dikelola oleh PT PLN Nusantara Power adalah UP Paiton Unit 1-2 yang berlokasi di Kecamatan Paiton, Kabupaten Probolinggo, Jawa Timur. PLTU Paiton Unit 1-2 merupakan pembangkit listrik tenaga uap berbahan bakar batu bara yang memiliki kapasitas terpasang masing-masing sebesar 400 MW, sehingga total kapasitas pembangkit mencapai 800 MW. Unit pembangkit ini berperan penting dalam mendukung pasokan listrik pada sistem interkoneksi Jawa-Madura-Bali (Jamali).

Sebagai salah satu unit pembangkit strategis nasional, PT PLN Nusantara Power UP Paiton Unit 1-2 terus melakukan berbagai upaya peningkatan keandalan operasi, efisiensi pembangkit, serta penerapan budaya Keselamatan dan Kesehatan Kerja (K3). Selain itu, perusahaan juga mendukung transformasi digital melalui pemanfaatan teknologi dan pengelolaan data untuk meningkatkan efektivitas proses bisnis dan operasional perusahaan.



Gambar 2.1.1 PLTU Paiton


Visi dan Misi Perusahaan:

- Visi
Menjadi perusahaan pembangkitan tenaga listrik terkemuka dan berkelanjutan di Indonesia serta mampu bersaing di tingkat regional melalui pengelolaan pembangkit yang andal, efisien, dan berorientasi pada inovasi.
- Misi
 1. Menyediakan energi listrik yang andal, efisien, dan berkelanjutan untuk

mendukung kebutuhan masyarakat dan pembangunan nasional.

2. Mengoptimalkan pengelolaan aset pembangkitan melalui penerapan teknologi, inovasi, dan transformasi digital.
3. Menerapkan tata kelola perusahaan yang baik serta berorientasi pada keselamatan, kesehatan kerja, dan kelestarian lingkungan.
4. Mengembangkan sumber daya manusia yang kompeten, profesional, dan berdaya saing.
5. Menciptakan nilai tambah bagi pemegang saham, pelanggan dan seluruh pemangku kepentingan.

2.2 Struktur Organisasi Perusahaan



Gambar 2.2.1 Struktur Organisasi PLN Nusantara Power UP Paiton

Struktur organisasi PT PLN Nusantara Power UP Paiton Unit 1-2 dipimpin oleh seorang Senior Manager yang bertanggung jawab atas keseluruhan kegiatan operasional, pemeliharaan, penjaminan mutu, serta fungsi pendukung bisnis di lingkungan perusahaan.

Bidang operasional terdiri atas Manager Operasi 1 dan Manager Operasi 2 yang bertanggung jawab terhadap kegiatan pengoperasian unit pembangkit, pengendalian operasi, produksi, penanganan batu bara (coal handling), serta pengelolaan aspek keselamatan dan keamanan kerja. Bidang pemeliharaan terdiri atas Manager Pemeliharaan 1 dan Manager Pemeliharaan 2 yang bertanggung jawab terhadap pemeliharaan boiler, turbin, *auxiliary* boiler, sistem listrik, serta sistem kontrol dan instrumen pembangkit.

Selain itu, terdapat Manager *Engineering & Quality Assurance* yang bertanggung jawab terhadap pengembangan sistem, keandalan pembangkit, pengendalian mutu, laboratorium, *condition based maintenance*, serta pengelolaan lingkungan. Fungsi pendukung perusahaan berada di bawah Manager *Business Support* yang membawahi bidang sumber daya manusia, pengendalian inventori dan gudang, pengadaan, serta sipil, umum, dan *corporate social responsibility* (CSR).

2.3 Lokasi Perusahaan



Gambar 2.3.1 Lokasi PLN Nusantara Power UP Paiton

PT PLN Nusantara Power UP Paiton Unit 1-2 berlokasi di Jalan Raya Surabaya – Situbondo KM 142, Kecamatan Paiton, Kabupaten Probolinggo, Provinsi Jawa Timur. Lokasi pembangkit berada di kawasan PLTU Paiton yang merupakan salah satu kompleks pembangkit listrik terbesar di Indonesia dan berperan penting dalam mendukung pasokan listrik pada sistem interkoneksi Jawa-Madura-Bali (Jamali).

Secara geografis, PT PLN Nusantara Power UP Paiton Unit 1-2 terletak di wilayah pesisir utara Pulau Jawa yang memiliki akses strategis terhadap jalur transportasi utama Surabaya–Situbondo. Lokasi perusahaan berada sekitar 35 km di sebelah timur Kota Probolinggo dan sekitar 140 km dari Kota Surabaya.

Posisi yang berada di kawasan pesisir memberikan keuntungan dalam mendukung operasional pembangkit listrik tenaga uap, terutama terkait kebutuhan pasokan air untuk proses pembangkitan. Selain itu, lokasi yang berdekatan dengan jaringan transmisi tegangan tinggi juga mendukung proses penyaluran energi listrik ke berbagai wilayah pada sistem kelistrikan Jawa-Bali.

2.4 Kesehatan dan Keselamatan Kerja

Keselamatan dan Kesehatan Kerja (K3) merupakan salah satu aspek penting dalam operasional PT PLN Nusantara Power UP Paiton Unit 1-2. Sebagai perusahaan yang bergerak di bidang pembangkitan tenaga listrik, perusahaan memiliki komitmen untuk menciptakan lingkungan kerja yang aman, sehat, dan bebas dari kecelakaan kerja melalui penerapan Sistem Manajemen Keselamatan dan Kesehatan Kerja (SMK3) secara berkelanjutan.

Penerapan K3 di lingkungan perusahaan bertujuan untuk mencegah dan mengurangi terjadinya kecelakaan kerja maupun penyakit akibat kerja, serta menciptakan kondisi kerja yang aman dan nyaman sehingga dapat mendukung produktivitas karyawan. Dalam pelaksanaannya, seluruh kegiatan operasional perusahaan mengacu pada peraturan perundang-undangan yang berlaku serta standar keselamatan yang telah ditetapkan oleh perusahaan.

Tanggung jawab penerapan K3 tidak hanya berada pada manajemen, tetapi juga menjadi

kewajiban seluruh pekerja, mitra kerja, dan tamu yang berada di lingkungan perusahaan. Setiap individu diwajibkan untuk mematuhi prosedur keselamatan kerja, menggunakan alat pelindung diri (APD) sesuai ketentuan, menjaga kebersihan dan kerapian area kerja, serta melaporkan setiap kondisi maupun tindakan yang berpotensi menimbulkan kecelakaan kerja.

Sebagai bagian dari upaya peningkatan budaya keselamatan kerja, PT PLN Nusantara Power UP Paiton Unit 1-2 juga menerapkan sistem pelaporan temuan K3 yang memungkinkan pekerja melaporkan kondisi tidak aman (unsafe condition) maupun tindakan tidak aman (unsafe action) yang ditemukan di lingkungan kerja. Data laporan tersebut menjadi salah satu sarana penting dalam proses monitoring, evaluasi, dan perbaikan berkelanjutan terhadap aspek keselamatan kerja di perusahaan.

2.5 Etika Profesi

AKHLAK merupakan budaya kerja utama di PT PLN Nusantara Power yang menjadi singkatan dari Amanah, Kompeten, Harmonis, Loyal, Adaptif, dan Kolaboratif.



Gambar 2.5.1 Etika Profesi PLN Nusantara Power

1. Amanah

Memegang teguh kepercayaan yang diberikan.

- Memenuhi janji dan komitmen.
- Bertanggung-jawab atas tugas, keputusan dan tindakan yang dilakukan.
- Berpegangan teguh kepada nilai moral dan etika.

2. Kompeten

Terus belajar dan mengembangkan kapabilitas.

- Meningkatkan kompetensi diri untuk menjawab tantangan yang selalu berubah.
- Membantu orang lain belajar.
- Menyelesaikan tugas dengan kualitas terbaik.

3. Harmonis

Saling peduli dan menghargai perbedaan.

- Menghargai setiap orang apapun latar belakangnya.
- Suka menolong orang lain.
- Membangun lingkungan kerja yang kondusif.

4. Loyal

Berdedikasi dan mengutamakan kepentingan Bangsa dan Negara.

- Menjaga nama baik sesama Karyawan, Pimpinan, BUMN dan Negara.
- Rela berkorban untuk mencapai tujuan yang lebih besar.
- Patuh kepada pimpinan sepanjang tidak bertentangan dengan hukum dan etika.

5. Adaptif

Terus berinovasi dan antusias dalam menggerakkan ataupun menghadapi perubahan.

- Cepat menyesuaikan diri untuk menjadi lebih baik.
- Terus menerus melakukan perbaikan mengikuti perkembangan teknologi.
- Bertindak proaktif

6. Kolaboratif

Membangun kerja sama yang strategis.

- a. Memberikan kesempatan kepada berbagai pihak untuk berkontribusi.
- b. Terbuka dalam bekerja sama untuk menghasilkan nilai tambah.
- c. Menggerakkan pemanfaatan berbagai sumber daya untuk tujuan bersama.

BAB III

HASIL KEGIATAN KERJA

3.1 Alur Pembangkit Listrik Tenaga Uap (PLTU)

Sistem pembangkitan pada PT PLN Nusantara Power UP Paiton Unit 1-2 memanfaatkan batu bara sebagai bahan bakar utama untuk menghasilkan energi panas pada boiler. Sementara itu, kebutuhan air umpan (feedwater) boiler berasal dari mata air klontong yang berjarang sekitar 10 km dari lokasi pembangkit. Air baku tersebut dipompa menuju fasilitas pengolahan air untuk diproses menjadi air demineralisasi (denim water) yang memenuhi standar kualitas sebagai fluida kerja dalam siklus pembangkitan. Adapun air laut digunakan sebagai media pendingin pada sistem kondensor.

Proses pembangkit dimulai dari batu bara yang disimpan pada area coal yard dan selanjutnya diangkut melalui sistem conveyor menuju mill (pulverizer). Di dalam mill, batu bara dihancurkan menjadi serbuk halus agar proses pembakaran berlangsung lebih efektif. Serbuk batu bara kemudian dialirkan menuju ruang bakar (furnace) pada boiler untuk menghasilkan energi panas.

Air demin yang telah memenuhi standar kualitas dipompa menuju sistem feedwater dan dialirkan secara bertahap melalui Low Pressure Heater (LP Heater), deaerator, High Pressure Heater (HP Heater), serta economizer. Pada LP Heater dan HP Heater, air menerima panas dari ekstraksi uap turbin sehingga temperatur air meningkat sebelum memasuki boiler. Selanjutnya pada deaerator dilakukan proses penghilangan oksigen dan gas-gas terlarut yang berpotensi menyebabkan korosi pada sistem perpipaan dan peralatan pembangkit.

Setelah melewati economizer, air memasuki boiler dan menerima energi panas hasil pembakaran batu bara hingga berubah menjadi uap bertekanan dan bertemperatur tinggi. Uap tersebut kemudian dialirkan menuju turbin uap untuk menggerakkan sudu-sudu turbin sehingga menghasilkan energi mekanik berupa putaran poros.

Poros turbin terhubung langsung dengan generator. Putaran yang dihasilkan turbin akan menggerakkan generator untuk mengubah energi mekanik menjadi energi listrik melalui prinsip induksi elektromagnetik. Energi listrik yang dihasilkan kemudian dinaikkan tegangannya menggunakan transformator utama (generator transformer) sebelum disalurkan ke Gardu Induk dan jaringan transmisi 500 kV interkoneksi Jawa-Bali.

Setelah melewati turbin, uap bekas dialirkan menuju kondensor untuk didinginkan dan diubah kembali menjadi air kondensat. Proses pendinginan pada kondensor menggunakan air laut yang dipompa melalui Cooling Water Pump (CWP). Air kondensat yang dihasilkan selanjutnya dipompa kembali menuju sistem feedwater untuk digunakan kembali dalam siklus pembangkitan.

Selain menghasilkan energi listrik, proses pembakaran batu bara juga menghasilkan residu berupa fly ash dan bottom ash. Fly ash yang terbawa bersama gas buang ditangkap menggunakan Electrostatic Precipitator (ESP) sebelum disimpan pada Fly Ash Silo. Sementara itu, bottom ash yang berada di bagian bawah boiler dikumpulkan pada Bottom Ash Silo untuk selanjutnya dipindahkan menuju area pengelolaan abu. Sistem ini bertujuan untuk mengurangi dampak lingkungan sekaligus menjaga keandalan operasional pembangkit.

Secara umum, proses pembangkitan listrik pada PLTU Paiton Unit 1-2 mengikuti prinsip Siklus Rankine, yaitu siklus tertutup yang melibatkan proses pembentukan uap, ekspansi pada turbin, kondensasi, dan pemompaan kembali air menuju boiler. Siklus ini memungkinkan air digunakan secara berulang dalam proses pembangkitan sehingga meningkatkan efisiensi operasi pembangkit.

3.2 Sistem Keselamatan dan Kesehatan Kerja (K3)

Keselamatan dan Kesehatan Kerja (K3) merupakan salah satu aspek penting dalam mendukung keandalan operasional PT PLN Nusantara Power UP Paiton Unit 1-2. Lingkungan kerja pembangkit listrik memiliki berbagai potensi bahaya yang berasal dari peralatan bertegangan tinggi, mesin berputar, sistem perpipaan bertekanan, aktivitas pemeliharaan, serta penggunaan bahan bakar dan bahan kimia. Oleh karena itu, perusahaan menerapkan berbagai program dan prosedur K3 guna meminimalkan risiko kecelakaan kerja dan menciptakan lingkungan kerja yang aman bagi seluruh pekerja.

Sebagai bagian dari upaya peningkatan budaya keselamatan kerja, PT PLN Nusantara Power UP Paiton Unit 1-2 menerapkan sistem pelaporan temuan K3 yang memungkinkan setiap pekerja melaporkan kondisi tidak aman (*unsafe condition*) maupun tindakan tidak aman (*unsafe action*) yang ditemukan selama aktivitas kerja. Sistem pelaporan tersebut menjadi salah satu sumber informasi penting dalam proses identifikasi bahaya, evaluasi risiko, serta perbaikan berkelanjutan terhadap penerapan K3 di lingkungan perusahaan. Konsep pelaporan bahaya dan kondisi tidak aman merupakan salah satu pendekatan yang banyak diterapkan dalam sistem manajemen keselamatan kerja untuk mendukung pencegahan kecelakaan kerja.

3.2.1 Penerapan K3

Penerapan K3 di PT PLN Nusantara Power UP Paiton Unit 1-2 dilakukan melalui berbagai kegiatan yang bertujuan untuk menjaga keselamatan pekerja serta keandalan operasional pembangkit. Beberapa bentuk penerapan K3 yang dilakukan antara lain penggunaan Alat Pelindung Diri (APD) sesuai jenis pekerjaan, pelaksanaan *safety briefing* sebelum pekerjaan dimulai, penerapan work permit atau izin kerja, inspeksi rutin area kerja, serta pelaporan potensi bahaya yang ditemukan di lapangan.

Selain itu, perusahaan juga mendorong partisipasi aktif seluruh pekerja dalam menjaga keselamatan kerja melalui pelaporan temuan K3, setiap pekerja diberikan kesempatan untuk melaporkan kondisi maupun tindakan yang berpotensi menimbulkan risiko keselamatan sehingga tindakan yang berpotensi menimbulkan risiko keselamatan sehingga tindakan perbaikan dapat segera dilakukan. Pelaporan tersebut menjadi bagian tindakan perbaikan dapat segera dilakukan. Pelaporan tersebut menjadi bagian penting dalam membangun budaya keselamatan (*safety culture*) dan meningkatkan kesadaran pekerja terhadap pentingnya aspek K3 di lingkungan kerja.

3.2.2 Sistem Pelaporan K3

Dalam mendukung penerapan budaya keselamatan kerja, PT PLN Nusantara Power UP Paiton Unit 1-2 menggunakan aplikasi **IZAT** sebagai media pelaporan dan pemantauan temuan K3 di lingkungan kerja. Aplikasi ini digunakan oleh pekerja untuk melaporkan berbagai kondisi tidak aman (*unsafe condition*) maupun tindakan tidak aman (*unsafe action*) yang ditemukan selama kegiatan operasional dan pemeliharaan pembangkit.

Melalui aplikasi IZAT, setiap pekerja dapat menginput informasi terkait temuan yang ditemukan, seperti deskripsi temuan, lokasi kejadian, dokumentasi pendukung, tanggal pelaporan, serta informasi lain yang diperlukan dalam proses tindak lanjut. Data yang telah masuk ke dalam sistem kemudian dapat dipantau dan dikelola oleh tim K3 sebagai bahan monitoring dan evaluasi terhadap kondisi keselamatan kerja di perusahaan.

Proses pelaporan dimulai ketika pekerja menemukan suatu kondisi atau tindakan yang berpotensi menimbulkan risiko keselamatan. Temuan tersebut kemudian dilaporkan melalui aplikasi IZAT dan selanjutnya diverifikasi oleh petugas K3. Setelah proses verifikasi dilakukan, laporan akan diklasifikasikan ke dalam kategori temuan yang telah ditetapkan perusahaan sebelum dilakukan tindak lanjut perbaikan maupun tindakan pencegahan yang diperlukan.

Data laporan K3 yang digunakan dalam proyek ini diperoleh dari aplikasi IZAT dengan periode Januari 2025 hingga Desember 2025. Selama periode tersebut, sistem telah mengumpulkan

ribuan laporan yang berasal dari berbagai unit kerja di lingkungan PT PLN Nusantara Power UP Paiton Unit 1-2. Data tersebut menjadi sumber informasi yang penting dalam proses identifikasi potensi bahaya serta evaluasi penerapan K3 secara berkelanjutan.

Meskipun proses pelaporan telah dilakukan secara digital melalui aplikasi IZAT, proses pengelompokan kategori temuan masih dilakukan secara manual oleh petugas K3 berdasarkan isi deskripsi laporan yang diberikan oleh pelapor. Seiring meningkatnya jumlah laporan yang masuk, proses tersebut membutuhkan waktu yang lebih lama serta berpotensi menimbulkan ketidakkonsistenan dalam penentuan kategori. Oleh karena itu, diperlukan suatu pendekatan yang dapat membantu mengotomatisasi proses klasifikasi laporan K3 agar lebih cepat, konsisten, dan efisien melalui pemanfaatan metode Machine Learning.

3.2.3 Kategori Temuan K3

Dalam sistem pelaporan K3 yang digunakan di PT PLN Nusantara Power UP Paiton Unit 1-2, setiap laporan temuan diklasifikasikan ke dalam kategori tertentu sesuai dengan jenis bahaya atau permasalahan yang dilaporkan. Pengelompokan kategori ini bertujuan untuk mempermudah proses monitoring, evaluasi, serta penentuan tindakan perbaikan yang diperlukan.

Kategori temuan yang digunakan dalam penelitian ini terdiri dari lima kategori utama, yaitu:

Kode	Kategori	Contoh Temuan
2	Housekeeping & 5S	Tumpahan oli, sampah berserakan, lantai licin
3	Fire & Emergency System	APAR tidak diperiksa, kotak P3K tidak lengkap
4	Peralatan & Mesin	Kabel terbuka, lanpu mati, pipa bocor
5	APD (Alat Pelindung Diri)	Helm rusak, tidak menggunakan APD
6	Perilaku Kerja (Behavior)	Temuan putung rokok, tidak mengurus <i>working permit</i>

Tabel 3.2.1 Kategori Temuan K3

3.3 Pengembangan Sistem Klasifikasi Otomatis Laporan K3

3.3.1 Identifikasi Masalah

PT PLN Nusantara Power UP Paiton Unit 1-2 telah menerapkan sistem pelaporan Keselamatan dan Kesehatan Kerja (K3) berbasis digital melalui aplikasi IZAT untuk mendokumentasikan berbagai temuan yang berkaitan dengan keselamatan dan kesehatan kerja. Melalui sistem tersebut, pekerja dapat melaporkan kondisi tidak aman (*unsafe condition*) maupun tindakan tidak aman (*unsafe action*) yang ditemukan selama aktivitas operasional dan pemeliharaan pembangkit.

Seiring meningkatnya partisipasi pekerja dalam pelaporan K3, jumlah data yang tersimpan pada aplikasi IZAT terus bertambah setiap tahunnya. Setiap laporan yang masuk harus diklasifikasikan ke dalam kategori yang telah ditetapkan perusahaan, seperti *Housekeeping & 5S*, *Fire & Emergency System*, Peralatan & Mesin, Alat Pelindung Diri (APD), dan Perilaku Kerja (*Behavior*). Selain itu, setiap kategori memiliki bobot risiko tertentu yang digunakan sebagai dasar dalam proses evaluasi dan tindak lanjut terhadap laporan.

Berdasarkan proses bisnis yang berjalan saat ini, penentuan kategori laporan dan bobot risiko masih dilakukan secara manual oleh petugas K3 dengan membaca deskripsi laporan yang diinput oleh pelapor. Proses tersebut masih dapat dilakukan ketika jumlah laporan yang masuk relatif sedikit. Namun, ketika volume laporan meningkat, proses klasifikasi menjadi lebih memakan waktu, mengurangi efisiensi pengelolaan data, dan berpotensi menimbulkan ketidakkonsistenan

dalam penentuan kategori akibat perbedaan interpretasi antarpetugas.

Permasalahan tersebut semakin kompleks karena deskripsi laporan yang ditulis oleh pelapor umumnya menggunakan variasi kata, istilah, singkatan maupun gaya penulisan yang berbeda-beda untuk menggambarkan kondisi yang serupa. Variasi bahasa tersebut menyebabkan proses klasifikasi manual menjadi lebih sulit dan meningkatkan potensi kesalahan dalam penentuan kategori laporan.

Kondisi tersebut berdampak pada efektivitas pengelolaan data K3, khususnya dalam proses monitoring, evaluasi, analisis tren kejadian, serta penentuan bobot risiko yang menjadi dasar pengambilan keputusan. Oleh karena itu, diperlukan suatu mekanisme yang mampu mengklasifikasikan laporan secara otomatis berdasarkan isi deskripsi yang diberikan oleh pelapor sehingga proses pengelompokan dapat dilakukan dengan lebih cepat, konsisten, dan akurat.

Sebagai upaya untuk mengatasi permasalahan tersebut, pada proyek ini dikembangkan modul klasifikasi otomatis laporan K3 menggunakan pendekatan *Machine Learning* berbasis pemrosesan bahasa alami (Natural Language Processing). Model yang digunakan merupakan IndoBERT yang telah melalui proses fine-tuning menggunakan data historis laporan K3 perusahaan untuk memprediksi kategori laporan. Hasil prediksi kategori kemudian digunakan sebagai dasar dalam proses pemetaan (mapping) bobot risiko berdasarkan aturan (rule-based mapping) yang telah ditetapkan perusahaan. Dengan pendekatan tersebut, proses penentuan kategori dan bobot risiko dapat dilakukan secara otomatis tanpa mengubah standar penilaian risiko yang telah diterapkan.

Pengembangan ini diharapkan mampu meningkatkan efisiensi proses pelaporan K3, mengurangi potensi *human error* dalam proses klasifikasi, meningkatkan konsistensi penentuan bobot risiko, serta mendukung digitalisasi pengelolaan Keselamatan dan Kesehatan Kerja di PT PLN Nusantara Power UP Paiton Unit 1-2.


3.3.2 Sistem Sebelum Pengembangan

Sebelum dilakukan pengembangan PT. PLN Nusantara Power UP Paiton Unit 1-2 telah menggunakan Sistem Informasi K3 sebagai media pelaporan kondisi tidak aman (unsafe condition) maupun tindakan tidak aman (unsafe action). Pengguna menginput judul dan deskripsi kejadian melalui aplikasi berbasis web, kemudian data laporan disimpan ke dalam basis data sistem.

Berdasarkan alur sistem yang berjalan, proses klasifikasi kategori belum dilakukan secara otomatis. Setelah laporan diterima, petugas K3 harus membaca isi deskripsi laporan secara manual untuk menentukan kategori kejadian sesuai dengan pedoman perusahaan. Kategori yang telah ditentukan selanjutnya digunakan sebagai dasar dalam pemberian bobot risiko sebelum laporan disimpan sebagai data akhir pada sistem.

Proses klasifikasi yang masih dilakukan secara manual menyebabkan petugas K3 harus melakukan interpretasi terhadap setiap deskripsi laporan secara satu per satu. Ketika jumlah laporan meningkat, proses ini memerlukan waktu yang lebih lama dan berpotensi menimbulkan ketidakkonsistenan dalam penentuan kategori akibat adanya perbedaan interpretasi antarpetugas.

Selain itu, deskripsi laporan yang dibuat oleh pengguna umumnya memiliki variasi penggunaan istilah, singkatan, maupun gaya penulisan yang berbeda-beda untuk menggambarkan kondisi yang serupa. Kondisi tersebut semakin menyulitkan proses klasifikasi secara manual dan dapat memengaruhi ketepatan penentuan kategori serta bobot risiko yang diberikan. Oleh karena itu, diperlukan pengembangan sistem yang mampu melakukan klasifikasi kategori secara otomatis sehingga proses pelaporan menjadi lebih cepat, konsisten, dan efisien.



Gambar 3.3.1 Alur Sistem Sebelum Pengembangan

3.3.3 Pengumpulan Data

Tahap pengumpulan data dilakukan sebagai langkah awal dalam pengembangan sistem klasifikasi otomatis laporan K3. Data yang digunakan dalam proyek ini berasal dari aplikasi IZAT yang digunakan oleh PT PLN Nusantara Power UP Paiton Unit 1-2 sebagai media pelaporan temuan Keselamatan dan Kesehatan Kerja (K3).

Dataset yang digunakan merupakan data laporan K3 periode Januari 2025 hingga Desember 2025 dengan total jumlah data sebanyak 4.108 data. Data tersebut berisi laporan kondisi tidak aman (*unsafe condition*) maupun tindakan tidak aman (*unsafe action*) yang dilaporkan oleh pekerja selama kegiatan operasional dan pemeliharaan pembangkit. Setiap data terdiri atas beberapa atribut, namun pada penelitian kali ini hanya menggunakan atribut tertentu yang berkaitan langsung dengan proses klasifikasi teks, yaitu judul kegiatan, deskripsi kejadian, dan kategori kejadian. Setiap laporan telah memiliki kategori temuan yang ditentukan oleh tim K3 dan digunakan sebagai label dalam proses pengembangan model klasifikasi. Atribut judul dan deskripsi digunakan sebagai data masukan (*input*) model, sedangkan kategori kejadian digunakan sebagai label (*target*) selama proses pelatihan model.

Selain dataset historis, peneliti juga memanfaatkan dokumen Kertas Kerja Inovasi IZAT UP Paiton yang berisi panduan kategori kejadian, bobot risiko, serta contoh kasus pada setiap kategori. Dokumen digunakan sebagai acuan dalam penyusunan aturan dan proses pelabelan data, sehingga kategori yang dihasilkan tetap konsisten dengan standar klasifikasi yang diterapkan oleh perusahaan.

Data historis yang sudah dikumpulkan selanjutnya masuk dalam tahapan pendekatan *hybrid NLP* yang meliputi *text preprocessing*, penyusunan aturan baris kata kunci (*keyword rules*), *semi-supervised labeling*, proses audit crosscheck, serta finalisasi dataset pelatihan. Tahapan tersebut dilakukan untuk menghasilkan dataset yang memiliki kualitas label yang baik sehingga mampu meningkatkan performa model klasifikasi.

3.3.4 Penyusunan Dataset

Penyusunan dataset merupakan tahapan awal dalam pengembangan model klasifikasi laporan K3. Dataset dibangun dari data historis yang diperoleh melalui Sistem Informasi Keselamatan dan Kesehatan Kerja (K3) PT PLN Nusantara Power UP Paiton Unit 1–2. Namun demikian, data historis yang tersedia belum sepenuhnya memiliki kualitas label yang konsisten sehingga belum dapat langsung digunakan sebagai data pelatihan model IndoBERT.

Oleh karena itu, pada penelitian ini digunakan pendekatan Hybrid Natural Language Processing (Hybrid NLP) untuk menghasilkan dataset dengan kualitas label yang lebih baik. Pendekatan ini mengombinasikan beberapa teknik, yaitu *text preprocessing*, penyusunan aturan berbasis kata kunci (*keyword rules*), *semi-supervised labeling*, proses audit data, cross-check hasil pelabelan, serta finalisasi dataset.

Pendekatan tersebut memanfaatkan pengetahuan domain (*domain knowledge*) yang dimiliki perusahaan melalui aturan berbasis kata kunci untuk melakukan pelabelan awal terhadap data laporan. Selanjutnya, hasil pelabelan diverifikasi melalui proses audit dan koreksi manual terhadap data yang masih ambigu. Dengan pendekatan ini, proses pelabelan manual dapat diminimalkan tanpa mengurangi kualitas dataset yang digunakan pada proses fine-tuning model IndoBERT. Berikut merupakan tahapan proses penyusunan dataset menggunakan *Hybrid NLP*:

3.3.5 penyusunan Dataset Awal

Tahap pertama dalam penyusunan dataset dilakukan dengan mengekstraksi data historis laporan K3 dari Sistem Informasi Keselamatan dan Kesehatan Kerja (K3) PT PLN Nusantara Power UP Paiton Unit 1–2. Data yang diperoleh merupakan laporan kondisi tidak aman (*unsafe*

3.3.6 Pemuatan Panduan Kategori Perusahaan

Setelah dataset awal berhasil disusun, tahapan berikutnya adalah memuat dokumen pedoman kategori yang digunakan oleh PT PLN Nusantara Power UP Paiton Unit 1-2 sebagai acuan dalam proses pelabelan data. Dokumen tersebut berasal dari Kertas Kerja Inovasi IZAT UP Paiton, khususnya pada *sheet* Penjelasan Bobot Kondisi.

Pada tahap ini dilakukan pembacaan file Microsoft Excel menggunakan *library* Pandas. Sistem mengambil informasi yang terdiri atas kategori, bobot kondisi, dan contoh temuan. Informasi tersebut digunakan sebagai referensi dalam penyusunan aturan berbasis kata kunci (keyword rules) pada proses semi-supervised labeling.

Seluruh data yang berhasil dimuat selanjutnya akan disimpan dalam bentuk struktur data (*dictionary*) sehingga dapat digunakan sebagai referensi pada proses penyusunan aturan keyword dan mekanisme mapping bobot di Sistem Informasi K3. Dengan demikian, standar kategori dan bobot yang digunakan pada sistem otomatis tetap mengikuti pedoman resmi yang telah ditetapkan oleh perusahaan.

kategori		bobot	contoh
3	1	Housekeeping & 5S	Tumpahan oli, lantai licin, sampah berserakan,...
4	2	Fire & Emergency System termasuk rambu rambu K3	APAR tidak diperiksa, Kotak P3K tidak lengkap dll
5	3	Peralatan & Mesin	Kabel sambungan terbuka, lampu mati, pipa keropos
6	4	APD (Alat Pelindung Diri)	Helm rusak, APD tidak dipakai dll
7	5	Perilaku Kerja (Behavior)	Temuan puntung rokok di area kerja, tidak meng...

Gambar 3.3.3 Hasil Pembacaan Panduan Kategori dan Bobot Perusahaan

3.3.7 Text Preprocessing

Setelah dataset awal berhasil disusun, tahapan berikutnya adalah melakukan text preprocessing. Tahapan ini merupakan bagian dari pendekatan Hybrid Natural Language Processing (Hybrid NLP) yang bertujuan untuk membersihkan dan menormalisasi data teks sebelum digunakan pada proses semi-supervised labeling maupun fine-tuning model IndoBERT.

Data laporan K3 yang berasal dari pengguna masih memiliki berbagai variasi penulisan, seperti kesalahan ejaan (typographical error), penggunaan singkatan, istilah teknis yang tidak konsisten, serta karakter-karakter yang tidak diperlukan. Variasi tersebut dapat memengaruhi kualitas representasi teks sehingga berpotensi menurunkan performa proses pelabelan maupun model klasifikasi. Oleh karena itu, diperlukan proses preprocessing untuk menghasilkan representasi teks yang lebih seragam dan sesuai dengan karakteristik data perusahaan.

Pada penelitian ini, proses text preprocessing diimplementasikan menggunakan fungsi `nlp_preprocessing_bert()` yang dikembangkan secara khusus berdasarkan karakteristik laporan K3 di PT PLN Nusantara Power UP Paiton Unit 1–2. Fungsi tersebut menggabungkan beberapa tahapan pembersihan (cleaning) dan normalisasi teks sehingga menghasilkan representasi teks yang lebih konsisten sebelum diproses pada tahapan berikutnya.

```

# 3. Preprocessing Function

typo_map = {
    'jockey pum':'jockey pump','patrol cek r':'patrol cek rambu','helem':'helm','helmet':'helm',
    'sefty':'safety','pake':'pakai','pakek':'pakai','wear pack':'wearpack','wearpak':'wearpack',
    'harnes':'harness','harnes':'harness','appar':'apar','taging':'tagging','grearing':'grating',
    'greeting':'grating','scaffolding':'scaffolding','schafolding':'scaffolding','skafolding':'scaffolding',
    'conduid':'conduit','hidryan':'hydrant','hidrant':'hydrant','metrial':'material','kropos':'keropos',
    'lampi':'lampu','yg':'yang','tdk':'tidak','dg':'dengan','blm':'belum','bh':'buah','ea':'buah'
}

KAMUS_K3_VALID = [
    'helm','hydrant','scaffolding','grating','conduit','jockey pump','transformer','trafo','apar',
    'panel','kabel','wearpack','harness','boiler','conveyor','crusher','pulley','lampu','keropos','material'
]

kata_kegiatan_sampah = [
    'patrol check','patrol chec','patrol p2k3','patroli p2k3','patroli unit','patrol unit','patroli',
    'patroli rutin','patrol rutin','patrol pedu','patroli','patrol','p2k3','temuan','check rutin','peduli unit'
]

def fuzzy_normalize_word(word):
    if len(word) <= 3:
        return word
    match = process.extractOne(word, KAMUS_K3_VALID)
    if match and match[1] >= 92:
        return match[0]
    return word

def nlp_preprocessing_bert(text):
    text = str(text).lower().strip()
    # hapus kata noise
    for kata in kata_kegiatan_sampah:
        text = re.sub(r'\b'+re.escape(kata)+r'\b','',text)
    # koreksi typo
    for salah, benar in typo_map.items():
        text = re.sub(r'\b'+re.escape(salah)+r'\b', benar, text)
    # fuzzy normalization
    words = [fuzzy_normalize_word(w) for w in text.split()]
    text = ' '.join(words)
    # hapus simbol
    text = re.sub(r'[^a-z0-9\s]', ' ', text)
    # normalisasi spasi
    cleaned_text = ' '.join(text.split()).strip()
    if cleaned_text == '':
        return "laporan umum k3"
    return cleaned_text

```


Gambar 3.3.4 Implementasi Fungsi Text Preprocessing

Tahapan *text preprocessing* yang diterapkan pada penelitian ini terdiri atas enam proses sebagai berikut:

1. Case Folding
Seluruh huruf pada teks diubah menjadi huruf kecil (*lowercase*) agar perbedaan penggunaan huruf kapital tidak dianggap sebagai kata yang berbeda selama proses pengolahan teks.
2. Noise Removal
Istilah yang tidak memberikan informasi penting terhadap proses klasifikasi, seperti frasa rutin pelaporan (*patrol unit*, *patroli P2K3*, *patrol check*, dan istilah sejenis), dihapus dari teks sehingga informasi yang tersisa lebih berfokus pada deskripsi kondisi atau tindakan yang dilaporkan.
3. Typographical Correction
Kesalahan penulisan (*typographical error*) diperbaiki menggunakan kamus koreksi (*typo map*) yang disusun berdasarkan hasil observasi terhadap data historis perusahaan. Sebagai contoh, kata "helem" diperbaiki menjadi "helm", sedangkan "hidryan" dinormalisasi menjadi "hydrant".
4. Normalisasi Istilah K3 Menggunakan *Fuzzy Matching*
Setelah proses koreksi ejaan, dilakukan normalisasi istilah menggunakan metode RapidFuzz untuk menghitung tingkat kemiripan (*similarity score*) antara kata pada laporan dengan kamus istilah K3 perusahaan. Apabila nilai kemiripan melebihi ambang batas yang telah ditentukan, kata tersebut akan diganti dengan istilah standar yang terdapat pada kamus. Tahapan ini membantu menyeragamkan berbagai variasi penulisan istilah teknis yang sering muncul pada laporan K3.

5. Cleaning Character
Karakter selain huruf dan angka, seperti tanda baca, simbol, maupun karakter khusus lainnya dihapus menggunakan *regular expression* sehingga hanya informasi tekstual yang relevan yang dipertahankan.
6. Whitespace Normalization
Spasi yang berlebih dihilangkan sehingga setiap kalimat memiliki format penulisan yang lebih seragam dan mudah diproses pada tahapan selanjutnya.

Secara keseluruhan alur proses *text preprocessing* yang di terapkan ditunjukkan sebagai berikut:



Gambar 3.3.5 Tahapan Text Preprocessing

Setelah seluruh tahapan selesai dilakukan, setiap data pada kolom `text_clean` berhasil ditransformasikan menjadi representasi teks baru yang disimpan pada kolom `text_bert`. Kolom `text_bert` selanjutnya digunakan sebagai masukan utama pada proses *semi-supervised labeling* dan *fine-tuning* model IndoBERT

```

# 4. Terapkan preprocessing

df['text_bert'] = df['text_clean'].apply(nlp_preprocessing_bert)
df[['text_clean', 'text_bert']].head()

```

	text_clean	text_bert
0	membran ro bekas membran bekas	membran ro bekas membran bekas
1	windsock rusak	windsock rusak
2	tidak menggunakan sepatu safety menggunakan se...	tidak menggunakan sepatu safety menggunakan se...
3	puntung rokok di arae lph ditemukan adanya pun...	puntung rokok di arae lph ditemukan adanya pun...
4	ada bekas abu rokok unsafe codition	ada bekas abu rokok unsafe codition

Gambar 3.3.6 Hasil Text Preprocessing

Berdasarkan hasil implementasi, proses text preprocessing berhasil menghasilkan data teks yang lebih bersih, konsisten, dan terstandarisasi tanpa menghilangkan informasi penting mengenai kondisi K3 yang dilaporkan. Hasil preprocessing tersebut menjadi dasar yang lebih baik untuk proses *semi-supervised labeling* dalam pendekatan Hybrid NLP serta meningkatkan kualitas data yang digunakan pada proses *fine-tuning* model IndoBERT.

3.4 Pembangunan Dataset

3.4.1 Penyusunan Aturan Keyword

Tahap pertama dalam pembangunan dataset berlabel adalah menyusun aturan berbasis kata kunci (*keyword rules*) yang digunakan sebagai dasar pelabelan awal (*initial labeling*) pada proses *semi-supervised labeling*. Aturan ini bertujuan untuk memeberikan label kategori secara otomatis erhadap laporan yang memiliki karakteristik atau kata kunci yang jelas sehingga dapat mengurangi jumlah data yang memerlukan proses pelabelan secara manual.

Penyusunan *keyword rules* dilakukan berdasarkan pedoman kategori yang digunakan oleh PT PLN Nusantara Power UP Paiton Unit 1–2, yaitu Kertas Kerja Inovasi IZAT UP Paiton, serta hasil analisis terhadap data historis laporan K3 perusahaan. Kombinasi kedua sumber tersebut memungkinkan aturan yang dibangun tidak hanya mengikuti standar klasifikasi perusahaan, tetapi juga mampu mengakomodasi variasi istilah yang sering digunakan dalam laporan oleh pengguna.

Pada penelitian ini, aturan disusun untuk lima kategori utama laporan K3, yaitu:

1. *Housekeeping & 5S*

2. *Fire & Emergency System* (termasuk rambu-rambu K3)
3. Peralatan & Mesin
4. APD (Alat Pelindung Diri)
5. Perilaku Kerja (*Behavior*)

Setiap kategori memiliki sekumpulan kata kunci yang mewakili karakteristik suatu kondisi atau tindakan yang dilaporkan. Sebagai contoh, kategori Housekeeping & 5S memiliki kata kunci seperti sampah, debu, lumut, dan genangan, sedangkan kategori Peralatan & Mesin memiliki kata kunci seperti panel, pompa, valve, dan conveyor. Apabila kata-kata tersebut ditemukan pada teks laporan, sistem akan menggunakannya sebagai indikasi awal untuk menentukan kategori yang sesuai.

Aturan berbasis kata kunci ini tidak digunakan sebagai model klasifikasi akhir, melainkan sebagai mekanisme weak labeling pada proses semi-supervised labeling. Hasil pelabelan awal selanjutnya akan melalui proses audit dan verifikasi untuk memastikan konsistensi label sebelum digunakan sebagai dataset pelatihan pada proses fine-tuning model IndoBERT.

```
# 2. Aturan Keyword PROJ-K3

aturan_keywords = [

    # 1. HOUSEKEEPING & 5S
    {
        "kat": "Housekeeping & 5S",
        "kw": [
            'sampah', 'kotor', 'debu', 'lumpur', 'lumut', 'licin', 'becek', 'kumuh',
            'oil', 'tumpahan', 'cecekan', 'genangan', 'menggenang',
            'material bekas', 'sisa material', 'barang bekas', 'plat bekas', 'besi bekas', 'kardus', 'triplek', 'kayu', 'bambu',
            'berserakan', 'berantakan', 'menumpuk', 'tumpukan',
            'toilet', 'kamar mandi', 'wastafel', 'urinoir', 'sabun', 'tisu', 'bau pesing',
            'limbah', 'majun', 'drum kosong', 'karung bekas'
        ]
    },

    # 2. FIRE & EMERGENCY SYSTEM
    {
        "kat": "Fire & Emergency System termasuk rambu rambu K3",
        "kw": [
            'apar', 'tabung apar', 'hydrant', 'hidran', 'plk', 'kotak plk',
            'eye wash', 'eyewash', 'fire', 'darurat', 'emergency',
            'jalur evakuasi', 'evakuasi', 'titik kumpul',
            'rambu', 'label k3', 'poster', 'stiker', 'neon box', 'sign board', 'safety sign'
        ]
    },

    # 3. PERALATAN & MESIN
    {
        "kat": "Peralatan & Mesin",
        "kw": [
            'kabel', 'lemari', 'tl', 'panel', 'junction box', 'saklar', 'stopkontak', 'cctv',
            'pipa', 'valve', 'mesin', 'motor', 'pompa', 'blower', 'fan', 'kipas',
            'conveyor', 'idler', 'roller', 'bearing', 'crane', 'hoist',
            'trafo', 'transformer', 'boiler', 'grating', 'handrail', 'guardrail', 'plafon', 'atap', 'pintu', 'pagar',
            'filter', 'jockey pump', 'windsock', 'bocor', 'pecah', 'patah', 'jebol', 'kendor', 'terkelupas', 'kupas',
            'karat', 'berkarat', 'korosif', 'mati', 'padam', 'redup', 'gelap', 'error'
        ]
    },

    # 4. APD (Alat Pelindung Diri)
    {
        "kat": "APD (Alat Pelindung Diri)",
        "kw": [
            'helm', 'helmet', 'sepatu', 'safety shoes', 'rompi', 'masker', 'sarung tangan', 'earplug', 'earmuff',
            'warpack', 'pdl', 'apd', 'pelampung', 'harness', 'body harness', 'kacamata', 'kacamata safety',
            'safety glass', 'face shield', 'baju selam'
        ]
    },

    # 5. PERILAKU KERJA (Behavior)
    {
        "kat": "Perilaku Kerja (Behavior)",
        "kw": [
            'rokok', 'merokok', 'pamerit', 'tjin kerja', 'izin kerja', 'ptw',
            'unsafe action', 'tidak sesuai prosedur', 'melanggar prosedur',
            'bercanda', 'tidak tertib', 'sembarangan', 'parkir', 'parkir motor', 'parkir mobil', 'parkir hidran', 'parkir akses', 'lph', 'ngebut'
        ]
    }
]
```

Gambar 3.4.1 Implementasi Aturan Keyword pada Proses Semi-supervised Labeling

3.4.2 Semi-supervised Labeling

Setelah aturan berbasis kata kunci (*keyword rules*) selesai disusun, tahap berikutnya adalah melakukan proses *semi-supervised labeling* untuk memberikan label kategori secara otomatis pada data laporan K3. Tahapan ini bertujuan untuk menghasilkan dataset berlabel dengan memanfaatkan kombinasi aturan berbasis domain (*domain knowledge*) dan pelabelan manual, sehingga jumlah data yang harus diberi label secara manual dapat dikurangi.

Pada penelitian ini, proses semi-supervised labeling diimplementasikan menggunakan tiga fungsi utama, yaitu `get_category()`, `fix_ambiguous_keterangan()`, dan `koreksi_keterangan_produksi()`. Ketiga fungsi tersebut bekerja secara bertahap untuk menentukan kategori laporan berdasarkan isi teks yang telah melalui proses text preprocessing.

Tahap pertama dilakukan menggunakan fungsi `get_category()`. Fungsi ini melakukan pencocokan (*matching*) antara kata-kata pada laporan dengan daftar keyword yang telah disusun pada tahap sebelumnya. Setiap keyword yang ditemukan memberikan skor pada kategori yang bersesuaian. Kategori dengan skor tertinggi dipilih sebagai hasil pelabelan awal (*initial labeling*).

Apabila tidak ditemukan keyword yang sesuai, maka data diberi status Pending.

Data yang masih berstatus Pending selanjutnya diproses menggunakan fungsi `fix_ambiguous_keterangan()`. Fungsi ini menerapkan sejumlah aturan tambahan (rule-based) untuk menangani laporan yang memiliki pola kalimat atau istilah tertentu yang belum berhasil dikenali pada proses sebelumnya. Aturan tersebut disusun berdasarkan hasil analisis terhadap data historis perusahaan sehingga sebagian data Pending masih dapat diberikan kategori secara otomatis.

Selanjutnya, data yang masih belum memperoleh kategori diproses menggunakan fungsi `koreksi_keterangan_produksi()`. Fungsi ini memuat aturan khusus berdasarkan karakteristik laporan di lingkungan produksi PT PLN Nusantara Power UP Paiton Unit 1–2, seperti penggunaan istilah operasional maupun singkatan yang umum digunakan oleh pekerja. Penambahan aturan tersebut bertujuan untuk meningkatkan jumlah data yang berhasil diberi label secara otomatis.

Data yang tetap belum dapat diklasifikasikan setelah melalui ketiga tahapan tersebut diberi status `Keep_Pending`. Data dengan status tersebut selanjutnya melalui proses pelabelan secara manual oleh penulis untuk memastikan setiap laporan memiliki kategori yang sesuai sebelum digunakan sebagai data pelatihan model.

```
# 3. Fungsi Semi-Supervised Labeling

def get_category(text):
    scores = {}
    for aturan in aturan_keywords:
        kategori = aturan['kat']
        score = 0
        for keyword in aturan['kw']:
            if re.search(r'\b' + re.escape(keyword) + r'\b', text.lower()):
                score += 1
        scores[kategori] = score
    best_category = max(scores, key=scores.get)
    if scores[best_category] == 0:
        return "Pending"
    return best_category
```

Gambar 3.4.2 Implementasi Aturan Penentuan Kategori Awal Menggunakan Keyword Matching

```
fix_ambiguous_keterangan(text):
    text = str(text).lower().strip()
    if any(w in text for w in ['mengenang', 'genangan', 'plat bekas', 'kardus', 'material bekas', 'sisa cat', 'batu bara', 'kebersihan', 'cleaning parit', 'urinoir mampet', 'air netes', 'sampah', 'kotor', 'berantakan']):
        return "Housekeeping & SS"
    if any(w in text for w in ['hidran', 'tinta warna', 'banner', 'pemadam', 'tabung refrigerating', 'eye wash', 'lodin', 'apan', 'p3k', 'rambu', 'sign', 'stiker', 'sticker', 'papan', 'label k3', 'poster', 'neon box', 'CD']):
        return "Fire & Emergency System termasuk rambu rambu K3"
    if any(w in text for w in ['alat cat', 'saluran air', 'sasis', 'material pasca', 'air tandon', 'nbeam', 'plat tajam', 'penutup', 'grese', 'slewing', 'pembuangan air', 'alat berat', 'safety filter', 'loader', 'umbo']):
        return "Peralatan & Mesin"
    if any(w in text for w in ['tidak ada penutup yang aman', 'rubber skirt', 'masker', 'helm', 'safety shoes', 'apd', 'sarung tangan']):
        return "APD (Alat Pelindung Diri)"
    if any(w in text for w in ['tidak pada tempatnya', 'peletakan baju', 'ptw', 'pkn', 'scrubbing', 'prosedur', 'ijin kerja', 'izin kerja', 'merokok', 'rokok', 'bercanda', 'unsafe', 'lph', 'parkir', 'tidak tertib']):
        return "Perilaku Kerja (Behavior)"
    return "Keep Pending"
```

Gambar 3.4.3 Implementasi Koreksi Kategori Menggunakan Aturan Tambahan (Fix Ambiguous)

```
koreksi_keterangan_produksi(text):
    text = str(text).lower().strip()
    if text in ['patrol unit', 'patroli unit', 'patrol chec', 'patrol check', 'patrol p2k3', 'patroli p2k3', 'peduli unit', 'patroli']:
        return "Pending"
    if any(w in text for w in ['tulisa di lar', 'tulisan dilar', 'papan peri', 'papan info']):
        return "Fire & Emergency System termasuk rambu rambu K3"
    if any(w in text for w in ['lampu pen', 'lampu luar', 'lampu mer', 'p2k3 lampi']):
        return "Peralatan & Mesin"
    if any(w in text for w in ['sepatu safe', 'sepatu tida', 'tidak pakai', 'tidak meng']):
        return "APD (Alat Pelindung Diri)"
    if any(w in text for w in ['patrol mat', 'patroli mat', 'banyak san', '3 karung']):
        return "Housekeeping & SS"
    if 'merokok' in text or 'rokok' in text or 'ada bekas' in text:
        return "Perilaku Kerja (Behavior)"
    return "Keep Original"
```

Gambar 3.4.4 Implementasi Koreksi Berdasarkan Pola Khusus Laporan K3

Hasil Semi-Supervised Labeling


Hasil penerapan *semi-supervised* labeling terhadap 4.108 data laporan menunjukkan bahwa sebagian besar data berhasil memperoleh kategori secara otomatis. Sebanyak 3.169 data berhasil diklasifikasikan menggunakan kombinasi keyword rules dan aturan tambahan, sedangkan 939 data masih memerlukan proses pelabelan secara manual karena tidak memenuhi aturan yang telah disusun

atau memiliki konteks yang ambigu.

Hasil Labeling	Jumlah Data
Jumlah dataset awal	4.108
Berhasil dikategorikan otomatis	3.169
Perlu pelabelan manual (Keep Pending)	939
Total	4.108

Tabel 3.4.1 Hasil Semi-supervised Labeling

Berdasarkan hasil tersebut, tingkat keberhasilan pelabelan otomatis mencapai sekitar 77,1% dari keseluruhan dataset. Sementara itu, 22,9% data masih memerlukan proses pelabelan manual karena memiliki konteks yang ambigu atau belum dapat diidentifikasi menggunakan aturan yang tersedia. Hasil ini menunjukkan bahwa pendekatan semi-supervised labeling mampu mengurangi beban pelabelan manual secara signifikan, sekaligus tetap mempertahankan kualitas dataset melalui proses verifikasi terhadap data yang belum berhasil dikategorikan secara otomatis.



```

display(
    df[['text_bert', 'kategori']].head(50)
)
[15] ✓ 1.8s

... Semi-supervised labeling selesai
    Jumlah data yang perlu labeling manual: 939
...

```

	text_bert	kategori
0	membran ro bekas membran bekas	Keep_Pending
1	windsock rusak	Peralatan & Mesin
2	tidak menggunakan sepatu safety menggunakan se...	APD (Alat Pelindung Diri)
3	puntung rokok di arae lph ditemukan adanya pun...	Perilaku Kerja (Behavior)
4	ada bekas abu rokok unsafe codition	Perilaku Kerja (Behavior)
5	tidak pakai apd helm tidak pakai helm dan baju...	APD (Alat Pelindung Diri)
6	lampu penerangan area kimia tank auxiliary boi...	Peralatan & Mesin
7	plat hampir terjatuh	Keep_Pending
8	merokok di area kerja tidak di perbolehkan	Perilaku Kerja (Behavior)
9	pihak ke 3 kerja tidak pakai helm	APD (Alat Pelindung Diri)
10	pekerjaan tidak memakai wearpack dan baju leng...	APD (Alat Pelindung Diri)
11	pekerja tidak memakai wearpack saat pasang sca...	APD (Alat Pelindung Diri)
12	lampu ruangan control room cpp lt 2 tutbin mat...	Peralatan & Mesin
13	tidak memakai baju pdl	APD (Alat Pelindung Diri)
14	lampu menggantung	Peralatan & Mesin
15	lampu ruangan padam	Peralatan & Mesin

Gambar 3.4.5 Hasil Penerapan Semi-supervised Labeling pada Dataset K3



```

#Data Auto
df_auto = (
    df[df['kategori']!='Keep_Pending']
    .copy()
)

print(len(df_auto))

3169

df_auto.to_excel(
    'semi_supervised_labeled.xlsx',
    index=False
)

```

Gambar 3.4.6 Proses Penyimpanan Dataset Hasil Auto Labeling

```
# Data Manual
df_manual = (
    df[df['kategori']=='Keep_Pending']
    .copy()
)

print(len(df_manual))

939

df_manual.to_excel(
    'manual_label.xlsx',
    index=False
)
```

Gambar 3.4.7 Proses Penyimpanan Dataset yang Memerlukan Pelabelan Manual

1	text_clean	text_bert	kategori
2	membran ro bekas membran bekas	membran ro bekas membran bekas	Keep_Pending
3	p2k3 plat hampir terjatuh	plat hampir terjatuh	Keep_Pending
4	patrol p2k3 ik hph 7 #1 yang di lokal mas	ik hph 7 1 yang di lokal masih belum di perbarui	Keep_Pending
5	patrol p2k3 belum berlabel np	belum berlabel np	Keep_Pending
6	patrol material tube sootblower tidak rapi	material tube sootblower tidak rapi	Keep_Pending
7	patrol cek list masih tahun 2024	cek list masih tahun 2024	Keep_Pending
8	patrol telpon bengkel m2 rusak	telpon bengkel m2 rusak	Keep_Pending
9	patrol check tidak ada maintenance box	tidak ada maintenance box untuk power listrik kalau ada po	Keep_Pending
10	patrol p2k3 tabung co2 belum di ganti ta	tabung co2 belum di ganti tagging belum di cek	Keep_Pending
11	p2k3 tangga ada yg kropos	tangga ada yang keropos	Keep_Pending
12	logo perusahaan belum di ganti masih m	logo perusahaan belum di ganti masih memakai logo lama	Keep_Pending
13	tdk tertata rapi tdk ditempat nya	tidak tertata rapi tidak ditempat nya	Keep_Pending
14	patrol p2k3 belum dicek	belum dicek	Keep_Pending
15	patrol p2k3 rawan hilang/rusak	rawan hilang rusak	Keep_Pending

Gambar 3.4.8 Dataset Sebelum Pelabelan Manual

1	text_clean	text_bert	kategori
2	membran ro bekas membran bekas	membran ro bekas membran bekas	Peralatan & Mesin
3	p2k3 plat hampir terjatuh	plat hampir terjatuh	Peralatan & Mesin
4	patrol p2k3 ik hph 7 #1 yang di lokal masih belum di	ik hph 7 1 yang di lokal masih belum di perbarui	Peralatan & Mesin
5	patrol p2k3 belum berlabel np	belum berlabel np	Housekeeping & SS
6	patrol material tube sootblower tidak rapi	material tube sootblower tidak rapi	Housekeeping & SS
7	patrol cek list masih tahun 2024	cek list masih tahun 2024	Housekeeping & SS
8	patrol telpon bengkel m2 rusak	telpon bengkel m2 rusak	Peralatan & Mesin
9	patrol check tidak ada maintenance box untuk powe	tidak ada maintenance box untuk power listrik kalau ai	Peralatan & Mesin
10	patrol p2k3 tabung co2 belum di ganti taging & belu	tabung co2 belum di ganti tagging belum di cek	Fire & Emergency System termasuk rambu rambu K3
11	p2k3 tangga ada yg kropos	tangga ada yang keropos	Peralatan & Mesin
12	logo perusahaan belum di ganti masih memakai log	logo perusahaan belum di ganti masih memakai logo le	Housekeeping & SS
13	tdk tertata rapi tdk ditempat nya	tidak tertata rapi tidak ditempat nya	Housekeeping & SS
14	patrol p2k3 belum dicek	belum dicek	Perilaku Kerja (Behavior)
15	patrol p2k3 rawan hilang/rusak	rawan hilang rusak	Peralatan & Mesin

Gambar 3.4.9 Dataset Setelah Pelabelan Manual

Dataset yang dihasilkan pada tahap ini selanjutnya digunakan pada proses validasi dan penyempurnaan dataset untuk memastikan konsistensi serta kualitas label sebelum digunakan sebagai data pelatihan pada proses fine-tuning model IndoBERT.

3.4.3 Audit Hasil Semi-supervised Labeling

Meskipun proses semi-supervised labeling berhasil memberikan kategori secara otomatis pada 3.169 data laporan, hasil pelabelan tersebut belum langsung digunakan sebagai dataset pelatihan. Untuk memastikan kualitas dan konsistensi label yang dihasilkan, dilakukan proses audit terhadap sebagian data hasil auto labeling.

Proses audit dilakukan dengan mengambil 300 data secara acak dari dataset semi_supervised_labeled.xlsx menggunakan teknik random sampling. Setiap data pada sampel

tersebut kemudian diperiksa secara manual dengan membandingkan kategori hasil pelabelan otomatis terhadap pedoman kategori yang digunakan oleh PT PLN Nusantara Power UP Paiton Unit 1–2. Selama proses pemeriksaan, ditambahkan kolom kategori_audit untuk mencatat kategori hasil koreksi apabila ditemukan ketidaksesuaian antara hasil pelabelan otomatis dan kategori yang seharusnya.

Audit ini bertujuan untuk mengevaluasi kualitas aturan berbasis kata kunci (keyword rules) yang digunakan pada proses semi-supervised labeling, mengidentifikasi pola kesalahan klasifikasi, serta memastikan bahwa label yang dihasilkan telah sesuai dengan standar klasifikasi perusahaan sebelum digunakan sebagai data pelatihan model IndoBERT.

Hasil audit menunjukkan bahwa dari 300 data yang diperiksa, sebanyak 271 data telah memiliki kategori yang sesuai dengan hasil pelabelan otomatis, sedangkan 29 data memerlukan perbaikan kategori. Temuan tersebut menunjukkan bahwa pendekatan semi-supervised labeling mampu menghasilkan label dengan tingkat ketepatan yang baik, meskipun masih terdapat beberapa kesalahan yang disebabkan oleh kemiripan konteks antar kategori maupun keterbatasan cakupan aturan berbasis kata kunci.

Selanjutnya, hasil audit diintegrasikan kembali ke dalam dataset utama dengan mengganti nilai kategori lama menggunakan hasil pada kolom kategori_audit, sehingga diperoleh dataset semi_supervised_labeled_v2.xlsx yang memiliki kualitas label yang lebih baik dan siap digunakan pada tahapan penyempurnaan dataset berikutnya.

Hasil Audit	Jumlah
Sampel yang diaudit	300
Sesuai	271
Perlu perbaikan	29

Tabel 3.4.2 Hasil Audit Semi-supervised Labeling

Proses pengambilan sampel, hasil audit manual, serta integrasi hasil audit ke dalam dataset utama

```
sample_audit = df_auto.sample(
    n=300,
    random_state=42
)

sample_audit.to_excel(
    'audit_300_data.xlsx',
    index=False
)
```

Gambar 3.4.10 Proses Pengambilan Sampel Audit Sebanyak 300 Data

	text_clean	text_bert	kategori	kategori_audit
1				
2	patrol check ditemukan sepeda parkir tidak pada t	ditemukan sepeda parkir tidak pada tempatnya	Perilaku Kerja (Behavior)	
3	perlengkapan apd tidak sesuai dengan standar	perlengkapan apd tidak sesuai dengan standar	APD (Alat Pelindung Diri)	
4	p2k3 wastafel cuci tangan kontainer tidak layak pi	wastafel cuci tangan kontainer tidak layak pakai be	Housekeeping & 5S	Peralatan & Mesin
5	patrol check terdapat tumpukan debu batu bara	terdapat tumpukan debu batu bara	Housekeeping & 5S	
6	lampu penerangan tripper 8 titik mati	lampu penerangan tripper 8 titik mati	Peralatan & Mesin	
7	papan rambu? sudah luntur	papan rambu sudah luntur	Fire & Emergency System termasuk rambu rambu K3	
8	patrol p2k3 filter / strainer alat berat waktunya re	filter strainer alat berat waktunya return	Peralatan & Mesin	
9	terdapat abu rokok di area kerja	terdapat abu rokok di area kerja	Perilaku Kerja (Behavior)	
10	banner tidak terpakaiganti baru / copot personel	banner tidak terpakaiganti baru copot personel sda	Fire & Emergency System termasuk rambu rambu K3	Housekeeping & 5S
11	patroli p2k3 material bekas tdk d buang pada tem	material bekas tidak d buang pada tempatnya	Housekeeping & 5S	
12	ac mati , sampling #1 mati tidak bisa di on	ac mati sampling 1 mati tidak bisa di on	Peralatan & Mesin	
13	patrol p2k3 apar tersedia, tapi belum dilakukan pe	apar tersedia tapi belum dilakukan pengecekan rutin	Fire & Emergency System termasuk rambu rambu K3	
14	lampu taman mati lampu mati	lampu taman mati lampu mati	Peralatan & Mesin	
15	pagar brc pagar kurang	pagar brc pagar kurang	Peralatan & Mesin	

Gambar 3.4.11 Dataset Hasil Audit Manual

```
# CEK HASIL

jumlah_perubahan = (
    df['kategori_lama'] != df['kategori']
).sum()

print(f"Jumlah kategori yang diperbaiki: {jumlah_perubahan}")

df.drop(columns='kategori_lama') \
    .to_excel(
        'semi_supervised_labeled_v2.xlsx',
        index=False
    )

print("File berhasil disimpan: semi_supervised_labeled_v2.xlsx")

Jumlah kategori yang diperbaiki: 29
File berhasil disimpan: semi_supervised_labeled_v2.xlsx
```

Gambar 3.4.12 Proses Integrasi Hasil Audit ke Dataset Utama

3.4.4 Crosscheck Berdasarkan Pola Kesalahan Audit

Setelah proses audit selesai dilakukan, tahap berikutnya adalah melakukan *crosscheck* terhadap seluruh data hasil *auto labeling*. Tahap ini bertujuan untuk memastikan bahwa pola kesalahan yang ditemukan selama proses audit tidak kembali muncul pada data lain yang belum diperiksa, sehingga kualitas dan konsistensi label dapat semakin ditingkatkan.

Proses *crosscheck* diawali dengan menganalisis hasil audit untuk mengidentifikasi pola kesalahan klasifikasi yang paling sering terjadi. Berdasarkan hasil analisis tersebut, disusun daftar kata kunci (*keyword*) yang berpotensi menyebabkan kesalahan pelabelan, seperti istilah yang berkaitan dengan APD, Housekeeping & 5S, hydrant, banner, parkir, serta berbagai istilah operasional lainnya yang memiliki konteks serupa.

Daftar kata kunci tersebut kemudian digunakan sebagai dasar pencarian terhadap seluruh 3.169 data hasil *auto labeling*. Tujuan dari proses ini adalah menemukan laporan yang memiliki karakteristik serupa dengan data yang sebelumnya teridentifikasi mengalami kesalahan klasifikasi, sehingga hanya data yang berpotensi bermasalah yang perlu diperiksa kembali secara manual.

Hasil proses *crosscheck* menunjukkan bahwa terdapat 934 data yang memiliki karakteristik sesuai dengan pola kesalahan hasil audit dan perlu dilakukan pemeriksaan ulang. Setelah melalui proses verifikasi secara manual, ditemukan 78 data yang memerlukan perubahan kategori. Seluruh hasil koreksi kemudian diintegrasikan kembali ke dalam dataset utama sehingga diperoleh dataset *semi_supervised_labeled_v3.xlsx*.

Tahapan *crosscheck* ini merupakan bentuk validasi lanjutan terhadap hasil *semi-supervised labeling*. Dengan memanfaatkan pola kesalahan yang diperoleh dari proses audit, kualitas label dapat ditingkatkan secara lebih efisien dibandingkan melakukan pemeriksaan ulang terhadap seluruh dataset. Hasil dari tahapan ini menghasilkan dataset dengan tingkat konsistensi yang lebih baik dan siap digunakan pada proses penyempurnaan dataset sebelum pelatihan model *IndoBERT*.

Hasil Crosscheck	Jumlah
Dataset auto labeling	3.169
Dataset yang diperiksa ulang	934
Data yang direvisi	78

Tabel 3.4.3 Hasil Crosscheck Dataset

Proses pencarian kandidat *crosscheck*, hasil pemeriksaan ulang, serta integrasi hasil koreksi ke dalam dataset utama

```
# HITUNG FREKUENSI

freq = Counter(words)

df_keyword = pd.DataFrame(
    freq.items(),
    columns=['keyword', 'frekuensi']
)

df_keyword = df_keyword.sort_values(
    by='frekuensi',
    ascending=False
)

display(df_keyword.head(30))
```

	keyword	frekuensi
8	rusak	5
28	tempatnnya	4
31	kabel	4
26	sepeda	4
47	berpotensi	3
32	papan	3
25	parkiran	3
56	motor	3

Gambar 3.4.13 Proses Pencarian Kandidat Crosscheck Berdasarkan Pola Kesalahan

	text_clean	text_bert	kategori
1			
2	tidak pakai apd helmet tidak pakai helmet dan	tidak pakai apd helm tidak pakai helm dan baj	APD (Alat Pelindung Diri)
3	patrol unit pihak ke 3 kerja tidak pakai helm	pihak ke 3 kerja tidak pakai helm	APD (Alat Pelindung Diri)
4	patrol peduli unit pekerjaan tidak memakai w	pekerjaan tidak memakai wearpack dan baju l	APD (Alat Pelindung Diri)
5	patrol p2k3 pekerja tidak memakai wearpack :	pekerja tidak memakai wearpack saat pasang	APD (Alat Pelindung Diri)
6	helper k3 pakek seragam pjb & helm pjb di ter	helper k3 pakai seragam pjb helm pjb di tertib	APD (Alat Pelindung Diri)
7	pekerja tidak pakai safety helmet rawan kecel	pekerja tidak pakai safety helm rawan kecelak	APD (Alat Pelindung Diri)
8	patrol sepeda tidak terparkir rapi	sepeda tidak terparkir rapi	Perilaku Kerja (Behavior)
9	patrol unit karyawan tidak pakai wearpack	karyawan tidak pakai wearpack	APD (Alat Pelindung Diri)
10	patrol p2k3 apar belum di lakukan chek rutin	apar belum di lakukan chek rutin	Fire & Emergency System termasuk rambu rambu K3
11	patrol p2k3 penempatan apar tidak standar	penempatan apar tidak standar	Fire & Emergency System termasuk rambu rambu K3
12	pengecekan apar rutin januari 2025 blm dilak	pengecekan apar rutin januari 2025 belum dil	Fire & Emergency System termasuk rambu rambu K3
13	rfid apar tidak ada rfid apar hilang	rfid apar tidak ada rfid apar hilang	Fire & Emergency System termasuk rambu rambu K3
14	patrol check line hydrant korosif & bocor	line hydrant korosif bocor	Fire & Emergency System termasuk rambu rambu K3
15	patrol check tidak memakai pelampung saat d	tidak memakai pelampung saat di jetty	APD (Alat Pelindung Diri)

Gambar 3.4.14 Dataset Hasil Crosscheck

```
# CEK HASIL

jumlah_perubahan = (
    df["kategori_lama"] != df["kategori"]
).sum()

print(f"Jumlah kategori yang diperbaiki: {jumlah_perubahan}")

df.drop(columns="kategori_lama") \
.to_excel(
    "semi_supervised_labeled_v3.xlsx",
    index=False
)

print("File berhasil disimpan: semi_supervised_labeled_v3.xlsx")
```

Jumlah kategori yang diperbaiki: 78
File berhasil disimpan: semi_supervised_labeled_v3.xlsx

Gambar 3.4.15 Integrasi Hasil Crosscheck ke Dataset Utama

3.5 Penyusunan Dataset Final

3.5.1 Penggabungan Dataset Hasil Pelabelan

Setelah seluruh proses validasi selesai dilakukan, tahap berikutnya adalah menyusun dataset final yang akan digunakan sebagai data pelatihan model IndoBERT. Dataset final dibentuk dengan menggabungkan dua sumber data, yaitu hasil semi-supervised labeling yang telah melalui proses audit dan crosscheck serta data yang sebelumnya memperoleh status Keep_Pending dan telah selesai dilakukan pelabelan secara manual.

Sebelum proses penggabungan dilakukan, kedua dataset terlebih dahulu disinkronisasi agar menggunakan struktur kolom yang sama, yaitu terdiri atas text_clean, text_bert, dan kategori. Penyamaan struktur data bertujuan untuk memastikan seluruh data dapat digabungkan tanpa menyebabkan ketidaksesuaian format.

Dataset hasil semi-supervised labeling yang telah divalidasi disimpan dengan nama semi_supervised_labeled_v3_done.xlsx, sedangkan dataset hasil pelabelan manual disimpan dengan nama manual_label_selesai_done.xlsx. Kedua dataset tersebut kemudian digabungkan menggunakan fungsi concat() pada library Pandas sehingga menghasilkan dataset akhir yang terdiri atas 4.108 data laporan.

Penggabungan ini menghasilkan satu dataset yang telah memiliki kategori pada seluruh data sehingga siap memasuki tahap finalisasi sebelum dilakukan proses pelatihan model klasifikasi menggunakan IndoBERT.

Sumber Dataset	Jumlah
Semi-supervised labeling (hasil audit dan crosscheck)	3.169
Pelabelan manual	939
Total Dataset Final	4.108

Tabel 3.5.1 Komposisi Dataset Final

1	text_clean	text_bert	kategori
2	windsock rusak	windsock rusak	Peralatan & Mesin
3	tidak menggunakan sepatu safety menggunakan se	tidak menggunakan sepatu safety menggunakan	APD (Alat Pelindung Diri)
4	puntung rokok di arae lph ditemukan adanya puntu	puntung rokok di arae lph ditemukan adanya p	Perilaku Kerja (Behavior)
5	ada bekas abu rokok unsafe codition	ada bekas abu rokok unsafe codition	Perilaku Kerja (Behavior)
6	tidak pakai apd helmet tidak pakai helmet dan baju	tidak pakai apd helm tidak pakai helm dan baju	APD (Alat Pelindung Diri)
7	lampu penerangan area kimia tank auxiliary boiler r	lampu penerangan area kimia tank auxiliary bo	Peralatan & Mesin
8	merokok di area kerja tidak di perbolehkan	merokok di area kerja tidak di perbolehkan	Perilaku Kerja (Behavior)
9	patrol unit pihak ke 3 kerja tidak pakai helm	pihak ke 3 kerja tidak pakai helm	APD (Alat Pelindung Diri)
10	patrol peduli unit pekerjaan tidak memakai wear pa	pekerjaan tidak memakai wearpack dan baju le	APD (Alat Pelindung Diri)
11	patrol p2k3 pekerja tidak memakai wearpack saat t	pekerja tidak memakai wearpack saat pasang s	APD (Alat Pelindung Diri)
12	lampu ruangan control room cpp lt.2 tutbin mati 3 t	lampu ruangan control room cpp lt 2 tutbin ma	Peralatan & Mesin
13	patrol check tidak memakai baju pdl	tidak memakai baju pdl	APD (Alat Pelindung Diri)
14	lampu menggantung	lampu menggantung	Peralatan & Mesin
15	lampu ruangan padam	lampu ruangan padam	Peralatan & Mesin

Gambar 3.5.1 Dataset Hasil Semi-supervised Labeling Setelah Validasi

1	text_clean	text_bert	kategori
2	membran ro bekas membran bekas	membran ro bekas membran bekas	Peralatan & Mesin
3	p2k3 plat hampir terjatuh	plat hampir terjatuh	Peralatan & Mesin
4	patrol p2k3 ik hph 7 #1 yang di lokal masih belum di	ik hph 7 1 yang di lokal masih belum di perbarui	Peralatan & Mesin
5	patrol p2k3 belum berlabel np	belum berlabel np	Housekeeping & 5S
6	patrol material tube sootblower tidak rapi	material tube sootblower tidak rapi	Housekeeping & 5S
7	patrol cek list masih tahun 2024	cek list masih tahun 2024	Housekeeping & 5S
8	patrol telpon bengkel m2 rusak	telpon bengkel m2 rusak	Peralatan & Mesin
9	patrol check tidak ada maintenance box untuk pow	tidak ada maintenance box untuk power listrik kalau ada pe	Peralatan & Mesin
10	patrol p2k3 tabung co2 belum di ganti taging & belu	tabung co2 belum di ganti tagging belum di cek	Fire & Emergency System termasuk rambu rambu K3
11	p2k3 tangga ada yg kropos	tangga ada yang keropos	Peralatan & Mesin
12	logo perusahaan belum di ganti masih memakai log	logo perusahaan belum di ganti masih memakai logo lama p	Housekeeping & 5S
13	tdk tertata rapi tdk ditempat nya	tidak tertata rapi tidak ditempat nya	Housekeeping & 5S
14	patrol p2k3 belum dicek	belum dicek	Perilaku Kerja (Behavior)
15	patrol p2k3 rawan hilang/rusak	rawan hilang rusak	Peralatan & Mesin

Gambar 3.5.2 Dataset Hasil Pelabelan Manual

```
# GABUNGAN

df_final = pd.concat(
    [df_main, df_manual],
    ignore_index=True
)

# CEK JUMLAH DATA

print("Jumlah data:", len(df_final))

df_final.to_excel(
    "dataset_final_4108.xlsx",
    index=False
)

print("Dataset final berhasil disimpan")

✓ 5.0s

Jumlah data: 4108
Dataset final berhasil disimpan
```

Gambar 3.5.3 Proses Penggabungan Kedua Dataset Menggunakan Pandas

	text_clean	text_bert	kategori
1	windsock rusak	windsock rusak	Peralatan & Mesin
2	tidak menggunakan sepatu safety mengguna	tidak menggunakan sepatu safety menggunakan sepat	APD (Alat Pelindung Diri)
3	puntung rokok di arae lph ditemukan adanya	puntung rokok di arae lph ditemukan adanya puntung	Perilaku Kerja (Behavior)
4	ada bekas abu rokok unsafe codition	ada bekas abu rokok unsafe codition	Perilaku Kerja (Behavior)
5	tidak pakai apd helmet tidak pakai helmet d	tidak pakai apd helm tidak pakai helm dan baju almam	APD (Alat Pelindung Diri)
6	lampu penerangan area kimia tank auxiliary	lampu penerangan area kimia tank auxiliary boiler mat	Peralatan & Mesin
7	merokok di area kerja tidak di perbolehkan	merokok di area kerja tidak di perbolehkan	Perilaku Kerja (Behavior)
8	patrol unit pihak ke 3 kerja tidak pakai helm	pihak ke 3 kerja tidak pakai helm	APD (Alat Pelindung Diri)
9	patrol peduli unit pekerjaan tidak memakai v	pekerjaan tidak memakai wearpack dan baju lengan pi	APD (Alat Pelindung Diri)
10	patrol p2k3 pekerja tidak memakai wearpac	pekerja tidak memakai wearpack saat pasang scaffold	APD (Alat Pelindung Diri)
11	lampu ruangan control room cpp lt.2 tutbin	lampu ruangan control room cpp lt 2 tutbin mati 3 titik	Peralatan & Mesin
12	patrol check tidak memakai baju pdl	tidak memakai baju pdl	APD (Alat Pelindung Diri)
13	lampu menggantung	lampu menggantung	Peralatan & Mesin
14	lampu ruangan padam	lampu ruangan padam	Peralatan & Mesin
15			

Gambar 3.5.4 Dataset Final Hasil Penggabungan Sebanyak 4.108 Data

3.5.2 Finalisasi Dataset untuk Pelatihan IndoBERT

Setelah dataset final berhasil dibentuk, tahap berikutnya adalah melakukan proses finalisasi dataset sebelum digunakan pada pelatihan model IndoBERT. Tahap ini bertujuan untuk memastikan bahwa seluruh data yang digunakan memiliki kualitas yang baik, tidak mengandung konflik label, serta sesuai dengan format masukan yang dibutuhkan oleh model.

Proses pertama dilakukan dengan membaca dataset dataset_final_4108.xlsx yang merupakan hasil penggabungan seluruh data auto labeling dan pelabelan manual. Pada tahap ini hanya dua atribut yang digunakan, yaitu text_bert sebagai representasi teks hasil preprocessing dan kategori sebagai label klasifikasi. Kolom lain tidak digunakan karena tidak berpengaruh terhadap proses pelatihan model.

Selanjutnya dilakukan proses pembersihan data (data cleaning) dengan menghapus data yang memiliki nilai kosong (missing value) maupun baris yang tidak memiliki isi teks atau kategori. Meskipun pada dataset ini tidak ditemukan data kosong yang signifikan, proses tersebut tetap dilakukan sebagai bagian dari validasi kualitas data.

Tahap berikutnya adalah melakukan pemeriksaan konflik label. Pemeriksaan ini bertujuan untuk memastikan bahwa setiap teks hanya memiliki satu kategori. Konflik label diperiksa dengan mengelompokkan data berdasarkan isi kolom text_bert kemudian menghitung jumlah kategori yang dimiliki setiap teks. Berdasarkan hasil pemeriksaan, tidak ditemukan konflik label sehingga seluruh

data dinyatakan konsisten dan dapat digunakan sebagai data pelatihan.


Selanjutnya dilakukan proses penghapusan data duplikat berdasarkan isi kolom text_bert. Penghapusan dilakukan untuk menghindari pengulangan data yang dapat menyebabkan model mengalami overfitting. Dari total 4.108 data, ditemukan 43 data duplikat sehingga jumlah data berkurang menjadi 4.065 data.

Tahap terakhir adalah melakukan pemeriksaan distribusi kategori untuk mengetahui keseimbangan jumlah data pada masing-masing kelas. Hasil pemeriksaan menunjukkan bahwa distribusi data masih bersifat tidak seimbang (imbalanced dataset), di mana kategori Peralatan & Mesin memiliki jumlah data paling banyak, sedangkan kategori APD (Alat Pelindung Diri) memiliki jumlah data paling sedikit. Informasi ini menjadi dasar dalam penerapan teknik class weight pada proses pelatihan model sehingga setiap kategori memperoleh perhatian yang proporsional selama proses pembelajaran.

Sebelum disimpan, nama kolom text_bert diubah menjadi text agar sesuai dengan format input yang digunakan pada proses tokenisasi IndoBERT. Dataset akhir kemudian disimpan dengan nama dataset_indobert_ready.xlsx dan digunakan sebagai dataset utama pada proses pembangunan model klasifikasi.

Tahapan	Jumlah
Dataset hasil penggabungan	4.108
Konflik label	0
Data duplikat yang dihapus	43
Dataset akhir	4.065

Tabel 3.5.2 Hasil Finalisasi Dataset



Gambar 3.5.5 Distribusi Dataset Berdasarkan Kategori

```

# FINALISASI DATASET UNTUK TRAINING INDOBERT

df_final = pd.read_excel(
    "dataset_final_4108.xlsx"
)

# AMBIL KOLOM YANG DIPERLUKAN

df_final = df_final[
    ['text_bert', 'kategori']
].copy()

# HAPUS DATA KOSONG

df_final = df_final.dropna(
    subset=['text_bert', 'kategori']
)

df_final['text_bert'] = (
    df_final['text_bert']
    .astype(str)
    .str.strip()
)

df_final['kategori'] = (
    df_final['kategori']
    .astype(str)
    .str.strip()
)

df_final = df_final[
    (df_final['text_bert'] != '')
    &
    (df_final['kategori'] != '')
]

print("Jumlah data setelah cleaning :", len(df_final))

# CEK KONFLIK LABEL

cek = (
    df_final
    .groupby('text_bert')['kategori']
    .nunique()
)

konflik = cek[cek > 1]

print(
    "Jumlah konflik label:",
    len(konflik)
)

if len(konflik) > 0:
    konflik_data = df_final[
        df_final['text_bert']
        .isin(konflik.index)
    ]

    display(
        konflik_data
        .sort_values('text_bert')
    )

# HAPUS DUPLIKAT

sebelum = len(df_final)

df_final = (
    df_final
    .drop_duplicates(
        subset=['text_bert'],
        keep='first'
    )
)

sesudah = len(df_final)

print("Sebelum :", sebelum)
print("Sesudah :", sesudah)

print(
    "Duplikat dihapus :",
    sebelum - sesudah
)

# CEK DISTRIBUSI KELAS

print("\nDistribusi kategori:")

print(
    df_final['kategori']
    .value_counts()
)

# UBAH NAMA KOLOM

df_final = df_final.rename(
    columns={
        'text_bert': 'text'
    }
)

df_final.to_excel(
    "dataset_indobert_ready.xlsx",
    index=False
)

print(
    "\nDataset final berhasil disimpan"
)

print(
    "Nama file : dataset_indobert_ready.xlsx"
)

```

Gambar 3.5.6 Proses Finalisasi Dataset Sebelum Pelatihan Model IndoBERT

```

Jumlah data setelah cleaning : 4108
Jumlah konflik label: 0
Sebelum : 4108
Sesudah : 4065
Duplikat dihapus : 43

Distribusi kategori:
kategori
Peralatan & Mesin                2098
Housekeeping & SS                1117
Fire & Emergency System termasuk rambu rambu K3  485
Perilaku Kerja (Behavior)        213
APD (Alat Pelindung Diri)        152
Name: count, dtype: int64

Dataset final berhasil disimpan
Nama file : dataset_indobert_ready.xlsx

```

Gambar 3.5.7 Hasil Proses Finalisasi

3.6 Implementasi Model IndoBERT

3.6.1 Persiapan Model IndoBERT

Setelah dataset hasil finalisasi berhasil disusun dan dibagi menjadi data pelatihan, data validasi, dan data pengujian, tahap berikutnya adalah melakukan persiapan model IndoBERT sebelum proses pelatihan dilakukan. Tahapan ini bertujuan untuk mengubah dataset yang masih berbentuk teks menjadi representasi numerik yang dapat dipahami oleh model deep learning.

Dataset yang digunakan pada tahap ini merupakan dataset hasil finalisasi yang telah melalui proses preprocessing, semi-supervised labeling, validasi manual, penghapusan data duplikat, serta pengecekan konflik label. Dataset tersebut disimpan dalam file `dataset_indobert_ready.xlsx` yang terdiri atas dua atribut utama, yaitu kolom `text` sebagai masukan model dan kolom `kategori` sebagai target klasifikasi.

Tahap pertama dilakukan dengan membaca dataset menggunakan pustaka **Pandas**. Setelah dataset berhasil dimuat, dilakukan pemeriksaan jumlah data untuk memastikan bahwa seluruh data hasil finalisasi telah terbaca dengan benar sebelum memasuki proses pelatihan model. Setelah dataset hasil finalisasi berhasil disusun dan dibagi menjadi data pelatihan, data validasi, dan data pengujian, tahap berikutnya adalah melakukan persiapan model IndoBERT sebelum proses pelatihan dilakukan. Tahapan ini bertujuan untuk mengubah dataset yang masih berbentuk teks menjadi representasi numerik yang dapat dipahami oleh model deep learning.

Dataset yang digunakan pada tahap ini merupakan dataset hasil finalisasi yang telah melalui proses preprocessing, semi-supervised labeling, validasi manual, penghapusan data duplikat, serta pengecekan konflik label. Dataset tersebut disimpan dalam file **`dataset_indobert_ready.xlsx`** yang terdiri atas dua atribut utama, yaitu kolom **`text`** sebagai masukan model dan kolom **`kategori`** sebagai target klasifikasi.

Tahap pertama dilakukan dengan membaca dataset menggunakan pustaka **Pandas**. Setelah dataset berhasil dimuat, dilakukan pemeriksaan jumlah data untuk memastikan bahwa seluruh data hasil finalisasi telah terbaca dengan benar sebelum memasuki proses pelatihan model.

```

df = pd.read_excel(
    "dataset_indobert_ready.xlsx"
)

print(df.head())

print()

print("Jumlah data :", len(df))

```

✓ 0.9s

```

      text \
0      windsock rusak
1 tidak menggunakan sepatu safety menggunakan se...
2 puntung rokok di arae lph ditemukan adanya pun...
3      ada bekas abu rokok unsafe codition
4 tidak pakai apd helm tidak pakai helm dan baju...

      kategori
0      Peralatan & Mesin
1 APD (Alat Pelindung Diri)
2 Perilaku Kerja (Behavior)
3 Perilaku Kerja (Behavior)
4 APD (Alat Pelindung Diri)

Jumlah data : 4065

```

Gambar 3.6.1 Implementasi Pembacaan Dataset Hasil Finalisasi Menggunakan Pandas

Hasil pembacaan menunjukkan bahwa dataset yang digunakan pada proses pelatihan terdiri atas 4.065 data yang telah siap digunakan sebagai data masukan model IndoBERT.

Selanjutnya dilakukan proses label encoding terhadap kolom kategori. Proses ini bertujuan untuk mengubah setiap kategori yang masih berbentuk teks menjadi nilai numerik karena model deep learning hanya dapat memproses data dalam bentuk bilangan. Setiap kategori diberikan indeks numerik yang bersifat unik sehingga hubungan antara label numerik dan nama kategori tetap dapat dipertahankan selama proses pelatihan maupun prediksi.

Proses label encoding dilakukan menggunakan kelas LabelEncoder dari pustaka scikit-learn. Hasil proses ini menghasilkan lima kelas kategori yang masing-masing direpresentasikan dalam bentuk indeks numerik mulai dari 0 hingga 4.

Hasil proses label encoding menghasilkan pemetaan kategori sebagai berikut.

Label	Kategori
0	APD (Alat Pelindung Diri)
1	Fire & Emergency System termasuk rambu-rambu K3
2	Housekeeping & 5S
3	Peralatan & Mesin
4	Perilaku Kerja (Behavior)

Tabel 3.6.1 Implementasi Proses Label Encoding

Dataset yang telah memiliki label numerik kemudian digunakan sebagai dasar untuk proses tokenisasi menggunakan tokenizer bawaan IndoBERT pada tahapan berikutnya.

```
df = pd.read_excel(
    "dataset_indoBERT_ready.xlsx"
)

print(df.head())

print()

print("Jumlah data :", len(df))
```

0.0s

	text \
0	windsock rusak
1	tidak menggunakan sepatu safety menggunakan se...
2	puntung rokok di arae lph ditemukan adanya pun...
3	ada bekas abu rokok unsafe codition
4	tidak pakai apd helm tidak pakai helm dan baju...

	kategori
0	Peralatan & Mesin
1	APD (Alat Pelindung Diri)
2	Perilaku Kerja (Behavior)
3	Perilaku Kerja (Behavior)
4	APD (Alat Pelindung Diri)

Jumlah data : 4065

Gambar 3.6.2 Pembacaan Dataset dataset_indoBERT_ready.xlsx

```
# LABEL ENCODING

label_encoder = LabelEncoder()

df['label'] = label_encoder.fit_transform(
    df['kategori']
)

print(label_encoder.classes_)

print()

print(df.head())
```

0.0s

Gambar 3.6.3 Implementasi Proses Label Encoding

```
['APD (Alat Pelindung Diri)'
 'Fire & Emergency System termasuk rambu rambu K3' 'Housekeeping & 5S'
 'Peralatan & Mesin' 'Perilaku Kerja (Behavior)']
```

	text \
0	windsock rusak
1	tidak menggunakan sepatu safety menggunakan se...
2	puntung rokok di arae lph ditemukan adanya pun...
3	ada bekas abu rokok unsafe codition
4	tidak pakai apd helm tidak pakai helm dan baju...


	kategori	label
0	Peralatan & Mesin	3
1	APD (Alat Pelindung Diri)	0
2	Perilaku Kerja (Behavior)	4
3	Perilaku Kerja (Behavior)	4
4	APD (Alat Pelindung Diri)	0

Gambar 3.6.4 Hasil Label Encoding

Dataset yang telah memiliki label numerik kemudian dibagi menjadi tiga bagian, yaitu data pelatihan (training set), data validasi (validation set), dan data pengujian (testing set). Pembagian dataset dilakukan menggunakan metode 80:10:10 dengan teknik stratified sampling, sehingga proporsi setiap kategori pada masing-masing subset tetap terjaga dan merepresentasikan distribusi kelas pada dataset asli.

Hasil pembagian dataset menghasilkan 3.252 data sebagai data pelatihan, 406 data sebagai data validasi, dan 407 data sebagai data pengujian.

Distribusi Dataset Setelah Pembagian



Gambar 3.6.5 Distribusi Pembagian Dataset Training, Validation, dan Testing

Tahapan persiapan model pada bagian ini menghasilkan dataset yang telah memiliki representasi label numerik serta telah dibagi menjadi tiga subset yang digunakan untuk proses pelatihan, validasi, dan evaluasi model. Dataset tersebut selanjutnya digunakan pada proses tokenisasi menggunakan tokenizer bawaan IndoBERT yang akan dibahas pada subbab berikutnya.

3.6.2 Tokenisasi Data Menggunakan IndoBERT

Setelah dataset selesai dipersiapkan dan dibagi menjadi data pelatihan, data validasi, serta data pengujian, tahap berikutnya adalah melakukan proses tokenisasi terhadap seluruh data teks. Tokenisasi merupakan tahapan penting dalam model berbasis Transformer karena model tidak dapat memproses teks secara langsung, melainkan memerlukan representasi numerik berupa token.

Pada penelitian ini digunakan tokenizer bawaan dari model `indobenchmark/indobert-base-p1` melalui pustaka `Transformers`. Tokenizer tersebut telah dilatih menggunakan korpus Bahasa Indonesia sehingga mampu mengenali struktur kata, sub-kata (subword), maupun berbagai variasi penulisan yang umum digunakan dalam Bahasa Indonesia.

Tahap pertama dilakukan dengan memanggil tokenizer menggunakan kelas `AutoTokenizer`. Tokenizer yang berhasil dimuat kemudian digunakan untuk mengubah seluruh data teks menjadi representasi token yang akan digunakan sebagai masukan model IndoBERT.

```
# LOAD TOKENIZER
MODEL_NAME = "indobenchmark/indobert-base-p1"
tokenizer = AutoTokenizer.from_pretrained(
    MODEL_NAME
)

Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
```

Gambar 3.6.6 Implementasi Pemanggilan Token IndoBERT

Selanjutnya dibuat sebuah fungsi tokenisasi yang digunakan untuk memproses seluruh data pelatihan, data validasi, dan data pengujian secara konsisten. Pada proses tokenisasi digunakan beberapa parameter penting, yaitu:

- `truncation=True`, digunakan untuk memotong teks yang melebihi panjang maksimum token.
- `padding=True`, digunakan untuk menyamakan panjang seluruh token dalam satu batch sehingga dapat diproses secara bersamaan.
- `max_length=128`, digunakan untuk membatasi panjang maksimum token menjadi 128 token.

Pemilihan panjang maksimum sebesar 128 token didasarkan pada karakteristik laporan K3 yang umumnya memiliki panjang kalimat relatif pendek. Dengan panjang tersebut, sebagian besar informasi penting masih dapat dipertahankan tanpa meningkatkan kompleksitas komputasi secara berlebihan.

Setelah fungsi tokenisasi selesai dibuat, proses tokenisasi diterapkan pada seluruh subset data, yaitu training set, validation set, dan testing set.

```
# TOKENIZATION

def tokenize(texts):

    return tokenizer(

        list(texts),

        truncation=True,

        padding=True,

        max_length=128

    )

train_encodings = tokenize(train_texts)

val_encodings = tokenize(val_texts)

test_encodings = tokenize(test_texts)

print("Tokenisasi selesai")
```

Gambar 3.6.7 Implementasi Proses Tokenisasi Dataset

Hasil tokenisasi menghasilkan beberapa komponen utama yang digunakan sebagai masukan model IndoBERT, yaitu `input_ids`, `attention_mask`, dan `token_type_ids`. Ketiga komponen tersebut merupakan representasi numerik dari setiap kalimat yang akan diproses pada tahap pelatihan model.

Berdasarkan hasil implementasi, proses tokenisasi berhasil dilakukan terhadap seluruh dataset tanpa mengalami kesalahan, sehingga seluruh data telah siap digunakan pada tahap pembentukan dataset PyTorch.

3.6.3 Pembentukan Dataset PyTorch

Setelah seluruh data berhasil ditokenisasi, tahap berikutnya adalah membentuk dataset dalam format PyTorch Dataset. Tahapan ini diperlukan karena model IndoBERT yang digunakan pada penelitian dibangun menggunakan framework PyTorch, sehingga data harus disusun dalam format yang dapat diproses secara langsung oleh proses pelatihan.

Pada penelitian ini dibuat sebuah kelas `K3Dataset` yang merupakan turunan dari kelas `torch.utils.data.Dataset`. Kelas tersebut berfungsi untuk menggabungkan hasil tokenisasi dengan label kategori sehingga setiap data memiliki pasangan antara fitur masukan (`input_ids`, `attention_mask`, dan `token_type_ids`) dengan label klasifikasi yang sesuai.

```
# PYTORCH DATASET

class K3Dataset(torch.utils.data.Dataset):

    def __init__(self, encodings, labels):

        self.encodings = encodings

        self.labels = labels

    def __getitem__(self, idx):

        item = {

            key: torch.tensor(val[idx])

            for key, val in self.encodings.items()

        }

        item['labels'] = torch.tensor(

            self.labels.iloc[idx]

        )

        return item

    def __len__(self):

        return len(self.labels)
```

Gambar 3.6.8 Implementasi Pembentukan Kelas K3 Dataset

Di dalam kelas tersebut terdapat tiga fungsi utama, yaitu:

6. `init()`, digunakan untuk menyimpan hasil tokenisasi dan label ke dalam objek dataset.
7. `getitem()`, digunakan untuk mengambil satu data beserta labelnya berdasarkan indeks tertentu.
8. `len()`, digunakan untuk mengembalikan jumlah data yang terdapat pada dataset.

Melalui ketiga fungsi tersebut, setiap data dapat diakses secara bertahap selama proses pelatihan tanpa harus memuat seluruh dataset ke dalam memori sekaligus. Pendekatan ini memberikan efisiensi penggunaan memori dan mempercepat proses pelatihan model.

Setelah kelas dataset berhasil dibuat, proses berikutnya adalah membentuk tiga objek dataset yang masing-masing digunakan sebagai data pelatihan, data validasi, dan data pengujian. Ketiga dataset tersebut dibangun menggunakan hasil tokenisasi pada masing-masing subset yang telah diperoleh pada tahap sebelumnya.

Pembagian dilakukan menggunakan fungsi `train_test_split()` sebanyak dua tahap dengan teknik stratified sampling sehingga proporsi setiap kategori tetap terjaga pada data pelatihan, validasi, maupun pengujian.

```
train_dataset = K3Dataset(

    train_encodings,

    train_labels.reset_index(drop=True)

)

val_dataset = K3Dataset(

    val_encodings,

    val_labels.reset_index(drop=True)

)

test_dataset = K3Dataset(

    test_encodings,

    test_labels.reset_index(drop=True)

)
```

Gambar 3.6.9 Implementasi Pembentukan Dataset Training, Validation, dan Testing

Hasil pembentukan dataset menunjukkan bahwa seluruh data telah berhasil dikonversi ke dalam format PyTorch Dataset sehingga dapat digunakan secara langsung oleh Trainer dari pustaka Transformers. Tahapan ini menjadi jembatan antara proses tokenisasi dengan proses pelatihan model IndoBERT yang akan dilakukan pada tahap berikutnya.

3.6.4 Penanganan Ketidakseimbangan Data Menggunakan Class Weight

Berdasarkan hasil finalisasi dataset, diketahui bahwa jumlah data pada masing-masing kategori tidak memiliki distribusi yang seimbang. Kategori Peralatan & Mesin memiliki jumlah data paling banyak, sedangkan kategori APD (Alat Pelindung Diri) dan Perilaku Kerja (Behavior) memiliki jumlah data yang relatif sedikit. Kondisi tersebut berpotensi menyebabkan model lebih cenderung mempelajari kategori mayoritas sehingga performa klasifikasi pada kategori minoritas menjadi kurang optimal.

Untuk mengatasi permasalahan tersebut, pada penelitian ini diterapkan teknik class weight sebelum proses pelatihan model dilakukan. Teknik ini bertujuan untuk memberikan bobot yang lebih besar pada kategori yang memiliki jumlah data lebih sedikit, sehingga kesalahan prediksi pada kategori minoritas akan memperoleh penalti yang lebih tinggi dibandingkan kategori mayoritas.

Perhitungan class weight dilakukan menggunakan fungsi `compute_class_weight()` dari pustaka `scikit-learn`. Nilai bobot dihitung berdasarkan distribusi jumlah data pada masing-masing kategori sehingga setiap kelas memperoleh bobot yang proporsional terhadap jumlah sampelnya.

```
# CLASS WEIGHT

classes = np.unique(df['label'])

class_weights = compute_class_weight(
    class_weight='balanced',
    classes=classes,
    y=df['label']
)

class_weights = torch.tensor(
    class_weights,
    dtype=torch.float
)

print(class_weights)
```

Gambar 3.6.10 Implementasi Perhitungan Class Weight

Hasil perhitungan menunjukkan bahwa kategori dengan jumlah data paling sedikit memperoleh bobot terbesar, sedangkan kategori dengan jumlah data terbanyak memperoleh bobot terkecil. Nilai class weight yang dihasilkan ditunjukkan sebagai berikut.

Kategori Kategori

Kategori	Kategori
APD (Alat Pelindung Diri)	5,3487
Fire & Emergency System termasuk rambu rambu K3	1,6763
Housekeeping & 5S	0,7278
Peralatan & Mesin	0,3875
Perilaku Kerja (Behavior)	0,38169

Tabel 3.6.2 Nilai Class Weight

Implementasi menghasilkan nilai bobot sebagai berikut.

```
tensor([5.3487, 1.6763, 0.7278, 0.3875, 3.8169])
```

Gambar 3.6.11 Hasil Perhitungan Class Weight

Penerapan class weight memungkinkan model memberikan perhatian yang lebih besar terhadap kategori yang memiliki jumlah data lebih sedikit selama proses pembelajaran. Dengan demikian, model tidak hanya berfokus pada kategori mayoritas, tetapi juga memiliki peluang yang lebih baik dalam mempelajari karakteristik kategori minoritas sehingga diharapkan mampu meningkatkan performa klasifikasi secara keseluruhan.

3.6.5 Pembangunan Model IndoBERT

Setelah dataset berhasil dipersiapkan dalam format PyTorch Dataset serta dilakukan penanganan ketidakseimbangan data menggunakan class weight, tahap berikutnya adalah membangun model klasifikasi berbasis IndoBERT. Pada penelitian ini digunakan model indobenchmark/indobert-base-p1 yang merupakan model bahasa Indonesia berbasis arsitektur Bidirectional Encoder Representations from Transformers (BERT).

Model IndoBERT dipilih karena telah melalui proses pre-training menggunakan korpus Bahasa Indonesia dalam jumlah besar sehingga memiliki kemampuan memahami hubungan antar kata berdasarkan konteks kalimat. Kemampuan tersebut sangat sesuai untuk proses klasifikasi laporan K3 yang memiliki variasi istilah teknis, singkatan, serta struktur kalimat yang beragam.

Pada penelitian ini, model dimuat menggunakan kelas `AutoModelForSequenceClassification` dari pustaka `Transformers`. Kelas tersebut memungkinkan model IndoBERT dimanfaatkan secara langsung untuk tugas klasifikasi dengan menambahkan lapisan klasifikasi (classification layer) pada bagian akhir jaringan.

```
# LOAD MODEL

model = AutoModelForSequenceClassification.from_pretrained(
    MODEL_NAME,
    num_labels=len(label_encoder.classes_)
)

print("Jumlah kelas :",
      len(label_encoder.classes_))
```

Gambar 3.6.12 Implementasi Pemanggilan Model IndoBERT

Jumlah neuron pada lapisan keluaran (output layer) disesuaikan dengan jumlah kategori yang digunakan pada penelitian, yaitu sebanyak lima kategori, meliputi:

1. APD (Alat Pelindung Diri)
2. Fire & Emergency System termasuk rambu-rambu K3
3. Housekeeping & 5S
4. Peralatan & Mesin
5. Perilaku Kerja (Behavior)

Parameter jumlah kelas ditentukan menggunakan nilai `num_labels`, sehingga model secara otomatis membangun lapisan klasifikasi yang sesuai dengan jumlah kategori pada dataset.

Ketika model pertama kali dimuat, lapisan klasifikasi belum memiliki bobot hasil pelatihan sehingga sistem melakukan inisialisasi bobot secara otomatis. Kondisi tersebut ditunjukkan oleh informasi `classifier.weight` dan `classifier.bias` yang berstatus `MISSING`. Hal tersebut merupakan kondisi yang normal karena lapisan klasifikasi memang akan dipelajari selama proses fine-tuning terhadap dataset K3.

```
Loading weights: 100% | 199/199 [00:00<00:00, 4857.77it/s]
[transformers] BertForSequenceClassification LOAD REPORT from: indobenchmark/indobert-base-pl
Key | Status |
-----|-----|
classifier.bias | MISSING |
classifier.weight | MISSING |

Notes:
- MISSING: those params were newly initialized because missing from the checkpoint. Consider training on your downstream task.
Jumlah kelas : 5
```

Gambar 3.6.13 Informasi Inisialisasi Lapisan Klasifikasi IndoBERT

Berdasarkan hasil implementasi, model berhasil dimuat dengan jumlah kelas sebanyak lima kelas, sesuai dengan jumlah kategori pada dataset yang digunakan. Tahapan ini menghasilkan model IndoBERT yang telah siap digunakan pada proses fine-tuning menggunakan dataset laporan K3 yang telah dipersiapkan pada tahapan sebelumnya.

3.6.6 Proses Fine-Tuning Model IndoBERT

Setelah seluruh tahapan persiapan model selesai dilakukan, tahap berikutnya adalah melakukan proses fine-tuning terhadap model IndoBERT menggunakan dataset laporan K3 yang telah dipersiapkan pada tahapan sebelumnya. Fine-tuning merupakan proses pelatihan ulang (transfer learning) terhadap model IndoBERT yang sebelumnya telah melalui proses pre-training, sehingga model dapat mempelajari karakteristik khusus dari laporan temuan K3 di PT PLN Nusantara Power UP Paiton Unit 1–2.

Pada penelitian ini, proses fine-tuning dilakukan menggunakan pustaka Transformers dari Hugging Face melalui kelas Trainer. Sebelum proses pelatihan dimulai, terlebih dahulu ditentukan metode evaluasi yang digunakan untuk mengukur performa model selama proses pembelajaran berlangsung.

- **Evaluasi Selama Proses Pelatihan**

Evaluasi model selama proses fine-tuning dilakukan menggunakan metrik Accuracy. Metrik ini dipilih karena penelitian berfokus pada permasalahan klasifikasi multikelas, sehingga accuracy mampu menunjukkan proporsi prediksi yang benar terhadap keseluruhan data validasi.

Perhitungan accuracy dilakukan melalui fungsi `compute_metrics()` yang menerima hasil prediksi model kemudian membandingkannya dengan label sebenarnya pada data validasi.

```
# METRIC EVALUATION
def compute_metrics(eval_pred):
    logits, labels = eval_pred
    predictions = np.argmax(
        logits,
        axis=1
    )
    acc = accuracy_score(
        labels,
        predictions
    )
    return {
        "accuracy": acc
    }
```

Gambar 3.6.14 Implementasi Fungsi `compute_metrics`

- **Penentuan Parameter Pelatihan**

Setelah fungsi evaluasi selesai dibuat, tahap berikutnya adalah menentukan parameter pelatihan (Training Arguments). Parameter ini mengatur mekanisme proses pembelajaran model selama fine-tuning berlangsung.

Parameter yang digunakan pada penelitian ini ditunjukkan pada Tabel 4.xx.

Parameter	Nilai
Learning Rate	2×10^{-5}
Batch Size Training	8
Batch Size Validation	8
Epoch	6
Weight Decay	0,01
Evaluation Strategy	Every Epoch
Save Strategy	Every Epoch
Load Best Model	True
Metric	Accuracy

Tabel 3.6.3 Parameter Fine-Tuning IndoBERT

Learning rate sebesar 2×10^{-5} dipilih karena merupakan nilai yang umum digunakan pada proses fine-tuning model BERT. Nilai tersebut memungkinkan model melakukan pembaruan parameter secara bertahap tanpa mengubah pengetahuan hasil pre-training secara berlebihan. Sementara itu, jumlah epoch ditetapkan sebanyak 6 epoch karena berdasarkan hasil pelatihan model telah mencapai performa yang stabil sebelum mulai mengalami kecenderungan peningkatan validation loss.

```
# TRAINING ARGUMENT
training_args = TrainingArguments(
    output_dir="./hasil_indobert",
    eval_strategy="epoch",
    save_strategy="epoch",
    learning_rate=2e-5,
    per_device_train_batch_size=8,
    per_device_eval_batch_size=8,
    num_train_epochs=6,
    weight_decay=0.01,
    load_best_model_at_end=True,
    metric_for_best_model="accuracy",
    logging_dir="./logs",
    logging_steps=50,
    save_total_limit=2
)
```

Gambar 3.6.15 Implementasi TrainingArguments

- **Pembentukan Trainer**

Setelah seluruh parameter pelatihan ditentukan, dilakukan pembentukan objek Trainer. Objek ini bertugas menghubungkan model IndoBERT, dataset pelatihan, dataset validasi, parameter pelatihan, serta fungsi evaluasi menjadi satu kesatuan proses pembelajaran. Dengan menggunakan kelas Trainer, proses pelatihan dapat dilakukan secara otomatis tanpa perlu membangun training loop secara manual.

```
# TRAINER

trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=train_dataset,
    eval_dataset=val_dataset,
    compute_metrics=compute_metrics
)
```

Gambar 3.6.16 Implementasi Pembentukan Objek Trainer

- **Proses Fine-Tuning Model**

Tahap berikutnya merupakan proses utama pada penelitian ini, yaitu melakukan fine-tuning menggunakan fungsi `trainer.train()`. Pada tahap ini model IndoBERT mulai mempelajari hubungan antara teks laporan temuan K3 dengan kategori yang telah diberikan pada dataset pelatihan.

Selama proses pelatihan, model melakukan pembaruan bobot parameter (weight update) pada setiap iterasi menggunakan data pelatihan sebanyak 3.252 data, kemudian melakukan evaluasi terhadap 406 data validasi pada setiap akhir epoch. Model terbaik dipilih secara otomatis berdasarkan nilai accuracy tertinggi pada data validasi karena parameter `load_best_model_at_end=True` telah diaktifkan.

Seluruh proses fine-tuning dijalankan menggunakan CPU, sehingga waktu pelatihan relatif lebih lama dibandingkan apabila menggunakan GPU. Berdasarkan hasil pelatihan, proses fine-tuning selesai dalam waktu sekitar 68 menit 12 detik.

```
# TRAINING

trainer.train()

✓ 68m 12.0s
```

Gambar 3.6.17 Implementasi Proses fine-tuning IndoBERT

[2442/2442 1:08:07, Epoch 6/6]			
Epoch	Training Loss	Validation Loss	Accuracy
1	0.417068	0.439898	0.871921
2	0.297970	0.486901	0.871921
3	0.121252	0.656780	0.881773
4	0.038410	0.692996	0.886700
5	0.046142	0.797051	0.879310
6	0.014863	0.726877	0.886700

Gambar 3.6.18 Hasil fine-tuning Model IndoBERT

Berdasarkan hasil pelatihan, nilai training loss mengalami penurunan secara konsisten dari 0,4171 pada epoch pertama menjadi 0,0149 pada epoch keenam. Hal ini menunjukkan bahwa model semakin mampu mempelajari pola hubungan antara teks laporan K3 dan kategori yang menjadi target klasifikasi.

Sementara itu, nilai validation accuracy menunjukkan peningkatan dari 87,19% pada epoch

pertama menjadi 88,67% pada epoch keenam. Meskipun terjadi peningkatan validation loss pada beberapa epoch, nilai accuracy tetap berada pada kisaran yang stabil sehingga menunjukkan bahwa model masih memiliki kemampuan generalisasi yang baik terhadap data validasi.

Secara keseluruhan, hasil fine-tuning menunjukkan bahwa model IndoBERT berhasil mempelajari karakteristik dataset laporan K3 dengan baik dan telah siap untuk dilakukan evaluasi menggunakan data pengujian (testing set) pada tahap berikutnya.

3.6.7 Evaluasi Model IndoBERT

Setelah proses fine-tuning selesai dilakukan dan model terbaik berhasil diperoleh, tahap berikutnya adalah melakukan evaluasi menggunakan data testing. Tujuan dari tahap ini adalah untuk mengetahui kemampuan model dalam mengklasifikasikan laporan temuan K3 yang belum pernah digunakan selama proses pelatihan maupun validasi. Dengan demikian, hasil evaluasi dapat menggambarkan kemampuan generalisasi model terhadap data baru.

Pada penelitian ini, proses evaluasi dilakukan menggunakan 407 data testing yang sebelumnya telah dipisahkan dari dataset pelatihan. Evaluasi dilakukan menggunakan fungsi `predict()` yang tersedia pada kelas `Trainer` dari pustaka `Transformers`. Fungsi tersebut menghasilkan prediksi kategori untuk setiap data testing, kemudian dibandingkan dengan label sebenarnya untuk menghitung berbagai metrik evaluasi.

```
# TEST EVALUATION

predictions = trainer.predict(
    test_dataset
)

y_pred = np.argmax(
    predictions.predictions,
    axis=1
)

y_true = test_labels.values

print(
    classification_report(
        y_true,
        y_pred,
        target_names=label_encoder.classes_
    )
)

print()

print(
    "Accuracy :",
    accuracy_score(
        y_true,
        y_pred
    )
)
```

Gambar 3.6.19 Implementasi Proses Evaluasi Model Menggunakan Data Testing

Hasil evaluasi model ditunjukkan melalui nilai precision, recall, F1-score, dan accuracy untuk masing-masing kategori. Precision menunjukkan tingkat ketepatan model dalam memberikan prediksi terhadap suatu kategori. Recall menunjukkan kemampuan model menemukan seluruh data yang benar-benar termasuk ke dalam kategori tersebut. Sementara itu, F1-score merupakan rata-rata harmonis antara precision dan recall sehingga mampu memberikan gambaran performa model secara

lebih seimbang.

	precision	recall	f1-score	support
APD (Alat Pelindung Diri)	0.83	1.00	0.91	15
Fire & Emergency System termasuk rambu rambu K3	0.82	0.96	0.89	49
Housekeeping & 5S	0.91	0.87	0.89	112
Peralatan & Mesin	0.94	0.93	0.94	210
Perilaku Kerja (Behavior)	0.83	0.71	0.77	21
accuracy			0.91	407
macro avg	0.87	0.89	0.88	407
weighted avg	0.91	0.91	0.91	407

Accuracy : 0.9066339066339066

Gambar 3.6.20 Hasil Classification Report Model IndoBERT

Secara keseluruhan model memperoleh accuracy sebesar 90,66% pada data testing. Nilai tersebut diperoleh menggunakan data testing yang sama sekali tidak digunakan selama proses pelatihan maupun validasi sehingga mampu menggambarkan kemampuan generalisasi model terhadap data baru.

Selain accuracy, nilai weighted average F1-score sebesar 0,91 menunjukkan bahwa performa model tetap baik meskipun distribusi jumlah data antar kategori tidak seimbang. Hal ini mengindikasikan bahwa model mampu mempertahankan keseimbangan antara precision dan recall pada keseluruhan kategori.

Berdasarkan hasil evaluasi tersebut, kategori Peralatan & Mesin menunjukkan performa terbaik dengan nilai precision sebesar 0,94, recall sebesar 0,93, dan F1-score sebesar 0,94. Hasil ini menunjukkan bahwa karakteristik laporan pada kategori tersebut relatif konsisten sehingga lebih mudah dipelajari oleh model IndoBERT.

Kategori Housekeeping & 5S juga menunjukkan performa yang baik dengan nilai F1-score sebesar 0,89, sedangkan kategori Fire & Emergency System termasuk rambu-rambu K3 memperoleh nilai F1-score sebesar 0,89 dengan recall yang tinggi, yaitu 0,96. Hal ini menunjukkan bahwa sebagian besar laporan pada kategori tersebut berhasil dikenali dengan benar oleh model.

Sementara itu, kategori APD (Alat Pelindung Diri) memperoleh nilai recall sebesar 1,00, yang berarti seluruh data APD pada data testing berhasil dikenali oleh model. Meskipun demikian, nilai precision sebesar 0,83 menunjukkan bahwa masih terdapat beberapa laporan dari kategori lain yang diprediksi sebagai APD.

Kategori dengan performa terendah adalah Perilaku Kerja (Behavior) yang memperoleh nilai F1-score sebesar 0,77. Nilai recall sebesar 0,71 menunjukkan bahwa masih terdapat beberapa laporan perilaku kerja yang diprediksi ke kategori lain. Kondisi ini dipengaruhi oleh jumlah data kategori tersebut yang relatif sedikit dibandingkan kategori lainnya serta adanya kemiripan konteks dengan kategori Housekeeping & 5S maupun Peralatan & Mesin.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa model IndoBERT telah mampu melakukan klasifikasi laporan temuan K3 dengan tingkat akurasi yang tinggi sehingga layak digunakan sebagai komponen utama dalam sistem otomatisasi penentuan kategori pada Web K3 PT PLN Nusantara Power UP Paiton Unit 1–2.

3.6.8 Analisis Confusion Matrix

Selain menggunakan metrik accuracy, precision, recall, dan F1-score, performa model juga dianalisis menggunakan confusion matrix. Confusion matrix digunakan untuk mengetahui hubungan antara kategori sebenarnya dengan kategori hasil prediksi model sehingga dapat diketahui kategori mana yang telah berhasil diprediksi dengan baik maupun kategori yang masih sering mengalami kesalahan klasifikasi.

Pada penelitian ini confusion matrix dibangun menggunakan fungsi `confusion_matrix()` dari pustaka `Scikit-learn`. Hasil confusion matrix kemudian divisualisasikan menggunakan pustaka `Seaborn` dalam bentuk heatmap agar lebih mudah dianalisis.

```

# CONFUSION MATRIX


cm = confusion_matrix(
    y_true,
    y_pred
)

plt.figure(figsize=(10,8))

sns.heatmap(
    cm,
    annot=True,
    fmt='d',
    cmap='Blues',
    xticklabels=label_encoder.classes_,
    yticklabels=label_encoder.classes_
)

```

Gambar 3.6.21 Implementasi Pembuatan Confusion Matrix Menggunakan Scikit-learn



Gambar 3.6.22 Hasil Confusion Matrix Model IndoBERT

Berdasarkan confusion matrix tersebut dapat diketahui bahwa sebagian besar data berhasil diprediksi pada kategori yang benar. Hal ini ditunjukkan oleh dominasi nilai pada diagonal utama (main diagonal) yang merepresentasikan jumlah prediksi benar pada setiap kategori.

Kategori **Peralatan & Mesin** merupakan kategori dengan jumlah prediksi benar tertinggi. Hasil ini sejalan dengan nilai precision dan recall yang tinggi pada classification report. Kondisi tersebut menunjukkan bahwa karakteristik laporan pada kategori Peralatan & Mesin relatif konsisten

sehingga mudah dikenali oleh model IndoBERT.

Kategori **Housekeeping & 5S** juga menunjukkan tingkat klasifikasi yang baik, meskipun masih terdapat beberapa data yang diprediksi sebagai kategori Peralatan & Mesin. Kesalahan ini terjadi karena beberapa laporan memiliki deskripsi yang mengandung kata-kata yang berhubungan dengan kondisi peralatan sekaligus kondisi kebersihan sehingga konteks antar kategori menjadi saling berdekatan.

Pada kategori **Fire & Emergency System** termasuk rambu-rambu K3, sebagian besar data berhasil diprediksi dengan benar. Hal ini menunjukkan bahwa laporan yang berkaitan dengan APAR, hydrant, rambu keselamatan, maupun fasilitas tanggap darurat memiliki karakteristik yang cukup spesifik sehingga mudah dipelajari oleh model.

Kategori **APD (Alat Pelindung Diri)** menunjukkan seluruh data testing berhasil dikenali oleh model sehingga nilai recall mencapai 100%. Namun demikian, masih terdapat beberapa laporan dari kategori lain yang diprediksi sebagai APD sehingga menyebabkan nilai precision sedikit lebih rendah dibandingkan recall.

Kesalahan klasifikasi paling banyak ditemukan pada kategori **Perilaku Kerja (Behavior)**. Beberapa laporan pada kategori ini diprediksi sebagai **Housekeeping & 5S** maupun **Peralatan & Mesin**. Kondisi tersebut disebabkan karena laporan perilaku kerja sering kali mengandung deskripsi kondisi lingkungan atau peralatan secara bersamaan, sehingga konteks kalimat menjadi lebih sulit dibedakan oleh model. Selain itu, jumlah data kategori Perilaku Kerja juga merupakan yang paling sedikit dibandingkan kategori lainnya sehingga proses pembelajaran model terhadap kategori tersebut menjadi lebih terbatas.

Secara keseluruhan, hasil confusion matrix menunjukkan bahwa model IndoBERT memiliki kemampuan klasifikasi yang baik terhadap lima kategori temuan K3. Sebagian besar prediksi berada pada diagonal utama, sedangkan kesalahan klasifikasi hanya terjadi pada beberapa laporan yang memiliki kemiripan konteks antar kategori. Hasil ini memperkuat nilai accuracy sebesar 90,66% yang diperoleh pada proses evaluasi sebelumnya.

3.6.9 Penyimpanan Model IndoBERT

Setelah model IndoBERT selesai melalui proses pelatihan dan evaluasi, tahap berikutnya adalah menyimpan model yang telah memiliki performa terbaik agar dapat digunakan kembali tanpa harus melakukan proses pelatihan ulang. Penyimpanan model merupakan tahapan penting karena model hasil fine-tuning selanjutnya akan diintegrasikan ke dalam sistem Web K3 sebagai komponen utama dalam proses klasifikasi otomatis.

Pada penelitian ini, proses penyimpanan dilakukan menggunakan fungsi `save_model()` yang tersedia pada kelas `Trainer` dari pustaka `Transformers`. Fungsi tersebut menyimpan seluruh parameter hasil fine-tuning beserta konfigurasi model ke dalam sebuah direktori bernama `model_indobert_k3`.

Selain model, tokenizer IndoBERT juga disimpan menggunakan fungsi `save_pretrained()`. Penyimpanan tokenizer bertujuan agar proses tokenisasi pada saat implementasi sistem menggunakan konfigurasi yang sama seperti saat proses pelatihan model. Dengan demikian, representasi token yang dihasilkan pada tahap implementasi tetap konsisten sehingga tidak menurunkan performa model.

Selanjutnya dilakukan penyimpanan Label Encoder menggunakan pustaka `Joblib`. Label encoder yang telah digunakan pada proses pelatihan disimpan dalam file `label_encoder.pkl` sehingga proses konversi antara label numerik dan nama kategori dapat dilakukan kembali pada saat proses prediksi di sistem.

```

# SIMPAN MODEL

trainer.save_model(
    "model_indobert_k3"
)

tokenizer.save_pretrained(
    "model_indobert_k3"
)

joblib.dump(
    label_encoder,
    "label_encoder.pkl"
)

print("Model berhasil disimpan")

```

Gambar 3.6.23 Implementasi Penyimpanan Model IndoBERT, Tokenizer, dan Label Encoder

Setelah proses penyimpanan selesai dilakukan, sistem menghasilkan tiga komponen utama yang akan digunakan pada tahap implementasi aplikasi, yaitu:

File	Fungsi
model_indobert_k3	Menyimpan model hasil fine-tuning beserta konfigurasi dan bobot parameter.
label_encoder.pkl	Menyimpan Label Encoder untuk mengubah hasil prediksi numerik menjadi nama kategori.
Tokenizer (di dalam folder model_indobert_k3)	Menyimpan konfigurasi tokenizer IndoBERT yang digunakan selama proses pelatihan.

Tabel 3.6.4 Hasil Penyimpanan Model IndoBERT

Keberhasilan proses penyimpanan ditunjukkan oleh pesan keluaran "Model berhasil disimpan", yang menandakan seluruh komponen telah tersimpan dengan baik dan siap digunakan pada tahap implementasi sistem. Dengan tersimpannya model, proses klasifikasi pada Web K3 nantinya tidak memerlukan proses pelatihan ulang, melainkan hanya memuat model yang telah tersedia untuk melakukan prediksi terhadap laporan temuan K3 yang baru.

3.7 Implementasi Model pada Web K3

Setelah model IndoBERT berhasil dilatih dan dievaluasi, tahap selanjutnya adalah mengimplementasikan model ke dalam sistem Web K3 PT PLN Nusantara Power UP Paiton. Implementasi ini bertujuan agar model yang telah dibangun tidak hanya digunakan sebagai hasil penelitian, tetapi juga dapat dimanfaatkan secara langsung untuk membantu proses klasifikasi kategori temuan K3 pada aplikasi yang telah digunakan oleh perusahaan.

Implementasi dilakukan dengan mengubah model hasil pelatihan menjadi sebuah layanan prediksi berbasis Application Programming Interface (API) menggunakan FastAPI. API tersebut kemudian diintegrasikan ke dalam source code Web K3 sehingga proses klasifikasi kategori dapat dilakukan secara otomatis ketika pengguna memasukkan data temuan. Seluruh proses implementasi meliputi persiapan deployment model, pembuatan API, pengujian API menggunakan Swagger, integrasi API ke dalam aplikasi web, hingga implementasi fitur prediksi pada Web K3.


3.7.1 Persiapan Deployment Model

Tahap pertama pada proses implementasi adalah mempersiapkan seluruh komponen yang diperlukan agar model hasil pelatihan dapat digunakan sebagai layanan prediksi. Model yang telah melalui proses fine-tuning pada penelitian ini sebelumnya telah disimpan menggunakan fungsi `save_model()` dari pustaka Transformers sehingga seluruh parameter hasil pelatihan dapat digunakan

kembali tanpa perlu melakukan proses pelatihan ulang.

Selain model IndoBERT, beberapa komponen pendukung juga dipersiapkan untuk mendukung proses deployment. Komponen tersebut meliputi tokenizer IndoBERT yang digunakan untuk melakukan tokenisasi terhadap data masukan, file `label_encoder.pkl` yang digunakan untuk mengubah hasil prediksi numerik menjadi nama kategori asli, serta berkas `app.py` yang berisi implementasi layanan API menggunakan FastAPI. Seluruh dependensi yang diperlukan juga dicatat ke dalam berkas `requirements.txt` sehingga lingkungan deployment dapat dibangun dengan konfigurasi yang sama seperti lingkungan pengembangan.

Dengan menyiapkan seluruh komponen tersebut, proses implementasi model ke dalam sistem dapat dilakukan tanpa perlu mengulangi proses pelatihan. Model hanya perlu dimuat kembali pada saat aplikasi dijalankan sehingga waktu implementasi menjadi lebih efisien.



Gambar 3.7.1 Struktur Folder Deployment Model IndoBERT K3.

3.7.2 Deployment API Menggunakan FastAPI

Setelah seluruh komponen deployment berhasil dipersiapkan, tahap berikutnya adalah membangun layanan prediksi menggunakan FastAPI. FastAPI dipilih karena merupakan framework Python yang ringan, memiliki performa tinggi, serta mampu membangun layanan REST API secara sederhana sehingga sesuai untuk mengimplementasikan model deep learning pada lingkungan produksi.

Pada penelitian ini, layanan API dibangun menggunakan berkas `app.py` yang bertugas sebagai penghubung antara model IndoBERT dengan aplikasi Web K3. Ketika API dijalankan, sistem akan memuat model hasil fine-tuning, tokenizer IndoBERT, serta label encoder yang sebelumnya telah disimpan. Ketiga komponen tersebut hanya dimuat satu kali pada saat aplikasi dijalankan sehingga proses prediksi dapat dilakukan dengan lebih cepat.

Selanjutnya dibuat sebuah endpoint POST `/predict` yang berfungsi menerima masukan berupa teks laporan K3. Data masukan dikirim dalam format JSON yang terdiri atas satu atribut, yaitu `text`. Teks yang diterima kemudian diproses menggunakan tokenizer IndoBERT sehingga berubah menjadi token numerik yang dapat dipahami oleh model. Hasil tokenisasi selanjutnya digunakan sebagai masukan model untuk menghasilkan prediksi kategori. Prediksi yang masih berupa indeks numerik kemudian dikembalikan menjadi nama kategori menggunakan LabelEncoder, kemudian dikirim kembali kepada pengguna dalam format JSON.

```

# Prediksi
with torch.no_grad():
    outputs = model(**inputs)
    probabilities = torch.softmax(
        outputs.logits,
        dim=1
    )
    confidence, prediction = torch.max(
        probabilities,
        dim=1
    )

# Konversi label
kategori = label_encoder.inverse_transform(
    [prediction.item()]
)[0]

return {
    "text": text,
    "kategori": kategori
}

```


Gambar 3.7.2 Implementasi Layanan Prediksi Menggunakan FastAPI.

Setelah proses pembuatan API selesai, tahap berikutnya adalah menjalankan layanan menggunakan Uvicorn sebagai ASGI Server. Server dijalankan menggunakan perintah berikut.

```
uvicorn app:app --host 0.0.0.0 --port 9000
```

Perintah tersebut membuat layanan prediksi dapat diakses melalui jaringan lokal perusahaan pada alamat IP server menggunakan port 9000. Selama layanan berjalan, setiap permintaan prediksi yang dikirimkan oleh aplikasi web akan diterima oleh endpoint /predict, diproses oleh model IndoBERT, kemudian hasil klasifikasi dikirimkan kembali kepada aplikasi.

Keberhasilan proses deployment ditunjukkan dengan munculnya status Application startup complete serta log HTTP 200 OK pada setiap permintaan prediksi yang diterima oleh server. Hal ini menunjukkan bahwa API berhasil dijalankan dan mampu memberikan respons terhadap setiap permintaan yang dikirimkan oleh aplikasi Web K3.



Gambar 3.7.4 Halaman Pengujian Endpoint Prediksi Menggunakan Swagger UI.

Pada proses pengujian, pengguna memasukkan contoh laporan K3 ke dalam atribut text, kemudian memilih tombol Execute untuk mengirim permintaan ke server. API selanjutnya memproses data menggunakan model IndoBERT dan mengembalikan hasil prediksi kategori secara otomatis. Pengujian ini bertujuan untuk memastikan bahwa endpoint /predict telah berfungsi dengan baik sebelum diintegrasikan ke dalam aplikasi Web K3.

Keberhasilan proses pengujian juga dapat diamati melalui log pada server FastAPI. Setiap permintaan yang dikirim melalui Swagger menghasilkan respons HTTP 200 OK, yang menunjukkan bahwa komunikasi antara client dan server berlangsung dengan baik serta model berhasil memberikan hasil klasifikasi sesuai permintaan.


3.7.4 Integrasi API ke Source Code Web & K3

Setelah proses pengujian API menggunakan Swagger berhasil dilakukan, tahap berikutnya adalah mengintegrasikan layanan prediksi berbasis IndoBERT ke dalam aplikasi Web K3 yang telah digunakan di PT PLN Nusantara Power UP Patiton Unit 1–2. Tahap ini bertujuan agar proses penentuan kategori temuan K3 dapat dilakukan secara otomatis melalui aplikasi tanpa mengubah alur kerja sistem yang telah digunakan sebelumnya.

Proses integrasi dilakukan pada sisi backend aplikasi menggunakan bahasa pemrograman JavaScript. Komunikasi antara aplikasi web dan layanan prediksi FastAPI dilakukan melalui protokol HTTP dengan memanfaatkan pustaka Axios. Pada penelitian ini dibuat fungsi predictText() yang bertugas mengirimkan permintaan HTTP POST menuju endpoint /predict beserta data laporan dalam format JSON.

Sebelum data dikirim ke layanan prediksi, atribut judul dan keterangan laporan terlebih dahulu digabungkan menjadi satu kalimat untuk memberikan konteks informasi yang lebih lengkap kepada model IndoBERT. Selanjutnya dilakukan proses pembersihan teks menggunakan fungsi cleanText() agar format masukan sesuai dengan data yang digunakan selama proses pelatihan model. Teks hasil preprocessing kemudian dikirim ke layanan FastAPI melalui fungsi predictText().

Hasil klasifikasi yang dikembalikan oleh layanan FastAPI selanjutnya diterima oleh fungsi batchPredict() dan disimpan ke dalam objek data sebagai kategori hasil prediksi. Proses tersebut dilakukan secara otomatis untuk setiap laporan sehingga seluruh data dapat diproses secara berurutan tanpa memerlukan pelabelan manual.



Gambar 3.7.5 Implementasi Integrasi Layanan Prediksi IndoBERT pada Backend Web K3

Melalui proses integrasi tersebut, aplikasi Web K3 berhasil terhubung dengan model IndoBERT yang telah di-fine-tuning. Setiap permintaan klasifikasi yang dilakukan pengguna akan dikirimkan ke layanan FastAPI, diproses menggunakan model IndoBERT, kemudian hasil kategori dikembalikan ke aplikasi untuk ditampilkan sebagai rekomendasi kategori temuan K3 secara otomatis.

3.7.5 Implementasi Fitur Prediksi pada Web K3

Tahap terakhir dalam penelitian ini adalah mengimplementasikan model IndoBERT ke dalam aplikasi Web K3 yang telah digunakan di PT PLN Nusantara Power UP Paiton Unit 1–2. Setelah proses deploy API dan integrasi backend berhasil dilakukan, fitur prediksi kategori kemudian diimplementasikan pada antarmuka aplikasi sehingga dapat digunakan secara langsung oleh pengguna.

Pada implementasi ini ditambahkan fitur Predict AI yang berfungsi untuk menjalankan proses klasifikasi kategori secara otomatis. Ketika pengguna memilih fitur tersebut, sistem akan mengambil data laporan berupa judul dan keterangan, kemudian mengirimkannya ke layanan FastAPI yang telah terhubung dengan model IndoBERT. Selanjutnya model melakukan proses inferensi dan mengembalikan hasil klasifikasi kategori kepada aplikasi.

Kategori hasil prediksi yang diperoleh kemudian ditampilkan pada halaman Web K3 sebagai rekomendasi kategori temuan. Hasil kategori tersebut selanjutnya digunakan sebagai dasar

dalam proses penentuan bobot kondisi sesuai dengan panduan yang telah ditetapkan oleh perusahaan. Dengan mekanisme tersebut, pengguna tidak lagi menentukan kategori secara manual sehingga proses pengisian data menjadi lebih cepat, lebih konsisten, dan mampu mengurangi potensi kesalahan pemberian bobot kondisi.

The screenshot displays the 'AI Klasifikasi Temuan' web application. The header bar is dark with the title 'AI Klasifikasi Temuan' and the subtitle 'Prediksi kategori berbasis Machine Learning'. Below the header, there's a navigation bar with three buttons: 'Sync Database Izat' (blue), 'Reload Temuan Baru' (orange), and 'Predict AI' (green). The main content area is titled 'Klasifikasi Kategori Data Temuan'. It features a table with the following columns: '#', 'Judul', 'Keterangan', and 'Kategori'. The table contains six rows of data, each with a yellow 'AI Suggestion' button next to the category dropdown. At the bottom right, there is a blue 'Simpan Data' button.

#	Judul	Keterangan	Kategori
1	Cor pendistrian lubang	Cor penutup pendistrian didepan gudang ada yg berlubang cukup besar	Peralatan & Mesin
2	Patrol P2K3	Apar belum diperiksa	Fire & Emergency System terma
3	Parkiran TAD sebelah selatan pos 2 tidak tertata rapi / berantakan	parkiran penuh karena banyak anak PKL / magang (tidak punya gatepass)	Perilaku Kerja (Behavior)
4	Logo PLNNP kuntur	kuntur	Housekeeping & SS
5	pintu bengkel mesin 1 eror	mechanical pintu abnormal	Peralatan & Mesin
6	warna STOP portal buram	sudah lama buram	Peralatan & Mesin

Gambar 3.7.6 Implementasi Fitur Predict AI pada Aplikasi Web K3

Berdasarkan hasil implementasi tersebut, model IndoBERT yang dikembangkan pada penelitian ini berhasil diintegrasikan ke dalam aplikasi Web K3 dan mampu digunakan untuk melakukan klasifikasi laporan secara otomatis. Dengan demikian, tujuan penelitian untuk mengoptimalkan proses penentuan kategori sebagai dasar pemberian bobot kondisi pada Web K3 telah berhasil dicapai.

BAB IV

KESIMPULAN DAN SARAN

4.1 Kesimpulan

Pelaksanaan program magang di PT PLN Nusantara Power UP Paiton Unit 1–2 telah berhasil menghasilkan pengembangan sistem klasifikasi otomatis laporan Keselamatan dan Kesehatan Kerja (K3) berbasis Deep Learning menggunakan model IndoBERT yang terintegrasi dengan Web K3 perusahaan. Sistem ini dikembangkan untuk mengatasi proses klasifikasi laporan K3 yang sebelumnya masih dilakukan secara manual sehingga membutuhkan waktu yang cukup lama dan berpotensi menimbulkan ketidakkonsistenan dalam penentuan kategori.

Pengembangan sistem diawali dengan penyusunan dataset menggunakan pendekatan Hybrid Natural Language Processing (Hybrid NLP) yang mengombinasikan text preprocessing, keyword rules, semi-supervised labeling, audit data, crosscheck, dan pelabelan manual. Dari total 4.108 data historis laporan K3 yang diperoleh dari aplikasi IZAT, berhasil dibentuk dataset final sebanyak 4.065 data yang telah melalui proses validasi dan pembersihan data. Proses semi-supervised labeling juga mampu mengurangi beban pelabelan manual dengan tingkat keberhasilan pelabelan otomatis sebesar 77,1%.

Berdasarkan hasil evaluasi menggunakan data testing, model IndoBERT memperoleh nilai accuracy sebesar 90,66% dan weighted average F1-score sebesar 0,91. Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang baik dalam mengklasifikasikan laporan K3 ke dalam lima kategori utama, yaitu Housekeeping & 5S, Fire & Emergency System, Peralatan & Mesin, APD (Alat Pelindung Diri), dan Perilaku Kerja (Behavior).

Model yang telah dilatih kemudian berhasil diimplementasikan dan diintegrasikan ke dalam Web K3 melalui layanan API berbasis FastAPI. Dengan adanya fitur Predict AI, proses penentuan kategori laporan dapat dilakukan secara otomatis sehingga membantu meningkatkan efisiensi kerja tim K3, mempercepat proses pengelolaan laporan, mengurangi potensi human error, serta mendukung transformasi digital pengelolaan Keselamatan dan Kesehatan Kerja di PT PLN Nusantara Power UP Paiton Unit 1–2.

4.2 Saran

Berdasarkan hasil pengembangan dan implementasi sistem yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan selanjutnya.


1. PT PLN Nusantara Power UP Paiton Unit 1–2 disarankan untuk terus memperbarui dan memvalidasi dataset laporan K3 secara berkala agar model dapat mempelajari pola-pola baru yang muncul pada laporan temuan sehingga performa klasifikasi tetap terjaga.
2. Penambahan jumlah data pada kategori yang masih memiliki jumlah sampel relatif sedikit, khususnya kategori Perilaku Kerja (Behavior), perlu dilakukan untuk meningkatkan kemampuan model dalam membedakan kategori yang memiliki konteks serupa.
3. Pengembangan berikutnya dapat mempertimbangkan penerapan mekanisme retraining model secara berkala agar sistem mampu beradaptasi terhadap perubahan istilah, singkatan, maupun pola pelaporan yang berkembang di lingkungan perusahaan.
4. Sistem dapat dikembangkan lebih lanjut dengan menambahkan fitur prediksi tingkat risiko, rekomendasi tindakan perbaikan, maupun analisis tren temuan K3 sehingga manfaat sistem tidak hanya terbatas pada klasifikasi kategori laporan.
5. Bagi mahasiswa atau peneliti selanjutnya, penelitian ini dapat dikembangkan dengan melakukan perbandingan performa beberapa model Deep Learning lainnya, seperti RoBERTa, XLM-RoBERTa, atau Large Language Model (LLM), untuk memperoleh model dengan tingkat akurasi yang lebih tinggi.
6. Program magang serupa perlu terus didukung karena memberikan kesempatan bagi mahasiswa untuk menerapkan keilmuan Sains Data pada permasalahan nyata di industri sekaligus menghasilkan solusi yang memberikan nilai tambah bagi perusahaan



DAFTAR PUSTAKA

- Amien, M. (2023) "Sejarah dan Pengembangan Teknik *Natural Language Processing* (NLP) Bahasa Indonesia: Tinjauan Tentang Sejarah, Perkembangan Teknologi, dan Aplikasi NLP dalam Bahasa Indonesia", *ELANG: Journal of Interdisciplinary Research* 1(1). doi: 10.32664/elang.v1i01.
- Global Energy Monitor. (2025) "PLN Paiton Power Station", Global Energy Monitor.
- Manderos, C., Kawatu, P.A.T. and Pangaribuan, M. (2024) "Gambaran Pelaksanaan Sistem Manajemen Keselamatan dan Kesehatan Kerja (SMK3) di PT. PLN (Persero) Unit Pelaksana Pelayanan Pelanggan (UP3) Tobelo", *Jurnal Kesehatan Masyarakat Universitas Sam Ratulangi* 13(1).
- Mubarokah, A., Ambarwati, R. and Dedy (2024) "Unsafe Conditions Identification Using Social Networks in Power Plant Safety Report", *Jurnal Manajemen, Teknik Informatika, dan Rekayasa Komputer* 23(2). doi: 10.30812/matrik.v23i2.3883
- Pangkey, S.J.I., Lengkong, V.P.K. and Saerang, R.T. (2023) "ANALISIS IMPLEMENTASI KESEHATAN DAN KESELAMATAN KERJA (K3) SEBAGAI UPAYA TERHADAP PENCEGAHAN KECELAKAAN KERJA DI PT. PLN (PERSERO) UP3 MANADO", *Jurnal EMBA* 11(4).
- PT PLN Nusantara Power, 2024. Code of Conduct (CoC) PT PLN Nusantara Power. Jakarta: PT PLN Nusantara Power.
- PT PLN Nusantara Power. (2025) "Profil Perusahaan", PT PLN Nusantara Power.
- PT PLN Nusantara Power. (2025) "Tentang Kami", PT PLN Nusantara Power.
- Tarigan, R., Akbar, G.G.M. and Ma'Sum. (2022) "Perancangan Sistem Informasi Pembuatan Laporan PJK3 Berbasis Web pada PT. Bintang Inspeksi Indonesia", *Jurnal Sains dan Informatika* 8(1). doi: 10.34128/jsi.v8i1.346.
- Widya, P.P., Ambarwati, R., Dedy and Alimova, M.T. (2024) "Leveraging Social Network Analysis for Enhancing Safety Reporting in the Workplace: A Case Study of the IZAT Application", *Jurnal Teknik Industri* 26(1). doi: 10.9744/jti.26.1.9-24

LAMPIRAN

[Demonstrasi Web](#)
[Source Code and Dataset](#)





AI Klasifikasi Temuan
Prediksi kategori berbasis Machine Learning

Klasifikasi Kategori Data Temuan

#	Judul	Keterangan	Kategori
1	Cat pencatatan hilang	Cat pencatatan pencatatan hilang (tidak ada yg bertanggung jawab) hilang	... pilih kategori ...
2	Patrol PKZ	Apa belum diperiksa	... pilih kategori ...
3	Parkiran TAC sebelah selatan area 2 tidak terawat rapi / berantakan	parkiran penuh karena banyak arak PKZ / memang tidak punya giliran	... pilih kategori ...
4	Logo PLN/PLN hilang	hilang	... pilih kategori ...
5	pipa bengkok mesin 1 error	mechanical pipa abnormal	... pilih kategori ...
6	tembok STCP retak buram	retak tembok buram	... pilih kategori ...

[Simpan Data](#)

